

Uniwersytet Mikołaja Kopernika w Toruniu

Wydział Matematyki i Informatyki

Szymon Orzechowski

nr albumu: **308190**

Kierunek studiów: Informatyka

Praca magisterska

**Programowanie równoległe w języku Chapel
na przykładzie problemu rozchodzenia się ciepła**

Promotor

dr. Marek Nowicki

Toruń, 2026

Spis treści

1	Wstęp	3
2	Problem i wykorzystane technologie	5
2.1	Równanie ciepła i metoda różnic skończonych	5
2.1.1	Model fizyczny	5
2.1.2	Warunki początkowe i brzegowe	5
2.1.3	Dyskretyzacja: jawna metoda różnic skończonych	6
2.1.4	Stabilność numeryczna i warunek CFL	7
2.2	Zrównoleglenie obliczeń stencilowych	9
2.2.1	Dekompozycja dziedziny i komórki brzegowe	9
2.2.2	Wymiana brzegów jako jedyna komunikacja	10
2.2.3	Intensywność arytmetyczna i ograniczenia wydajności	11
2.2.4	Miary skalowalności	11
2.3	Chapel, PGAS i GASNet	12
2.3.1	Język Chapel i model PGAS	12
2.3.2	Iteratory równoległe i tablice globalne	13
2.3.3	Konstrukcje równoległości i synchronizacja	14
2.3.4	Warstwa zadań qthreads oraz warstwa komunikacji GASNet	16
2.3.5	Kanały komunikacyjne GASNet	16
3	Klaster i implementacja	18
3.1	Architektura klastra i środowisko	18
3.1.1	Sprzęt i topologia	18
3.1.2	Konfiguracja kompilatora Chapel	19
3.1.3	Dwa kanały komunikacyjne GASNet	20
3.1.4	Uruchamianie i samoopisujące się logi	20
3.1.5	Procedura wdrożenia krok po kroku	21
3.1.6	Uruchamianie eksperymentu	22
3.2	Struktura programu i krok obliczeniowy	24
3.2.1	Dziedzina rozproszona z otoczką	24

3.2.2	Pojedynczy krok obliczeniowy	24
3.2.3	Ewolucja implementacji i operator zamiany buforów	25
3.2.4	Pomiar czasu i rejestrowanie	27
3.2.5	Parametry konfiguracyjne	28
3.2.6	Rejestrowanie przebiegów	28
3.3	Buforowanie, zapis i agregacja danych	29
3.3.1	Zapis fragmentów na dysk lokalny	29
3.3.2	Agregacja rozproszonych fragmentów	29
3.3.3	Wizualizacja	30
4	Metodologia badań	32
4.1	Scenariusze i metryki	32
4.1.1	Scenariusze badawcze	32
4.1.2	Metryki	33
4.2	Procedura i narzędzia pomiarowe	34
4.2.1	Procedura pomiarowa	34
4.2.2	Narzędzia pomiarowe	35
4.2.3	Przykład wyznaczenia metryk	36
4.2.4	Kontrola warunków i zagrożenia dla trafności	36
5	Wyniki i analiza	37
5.1	Poprawność i wydajność wariantów	37
5.1.1	Weryfikacja poprawności numerycznej	37
5.1.2	Skalowanie wątkowe na pojedynczym węźle	38
5.2	Skalowanie i ograniczenia komunikacji	40
5.2.1	Skalowanie liczbą węzłów	40
5.2.2	Skalowanie wątkowe przy dziewięciu węzłach	42
5.2.3	Skalowanie rozmiaru zadania	42
5.2.4	Synteza: system ograniczony komunikacją	44
5.2.5	Zestawienie zbiorcze i powtarzalność	45
6	Podsumowanie i wnioski	47
6.1	Wnioski	47
6.2	Ograniczenia	48
6.2.1	Kierunki dalszych prac	48
	Bibliografia	50

Rozdział 1

Wstęp

Symulacje zjawisk opisanych równaniami różniczkowymi cząstkowymi należą do najczęściej spotykanych zadań obliczeniowych w nauce i inżynierii. Wśród nich szczególnie miejsce zajmują obliczenia *stencilowe*, czyli takie, w których nowa wartość w każdym punkcie siatki jest funkcją wartości z punktów sąsiadujących. Wzorzec ten sprawia, że wydajne i skalowalne wykonanie obliczeń stencilowych na współczesnych architekturach równoległych stanowi wyzwanie [16].

Trójwymiarowe równanie przewodnictwa ciepła jest tradycyjnym przykładem takiego problemu. Jego jawna dyskretyzacja różnicowa ma dokładnie te cechy, które sprawiają, że obliczenia stencilowe są trudne do zrównoleglenia: niską intensywność arytmetyczną oraz konieczność wymiany danych brzegowych między częściami dziedziny w każdym kroku czasowym. Program symulujący równanie ciepła nadaje się dobrze do badania granic skalowalności. Choć wzorzec komunikacji jest tu prosty i ograniczony do wymiany z najbliższymi sąsiadami, a nie do komunikacji każdy z każdym jak w przekształceniach Fouriera, to właśnie przy licznych węzłach każda taka wymiana obciąża to samo, współdzielone łącze sieciowe, co czyni problem dobrym obiektem do ujawniania ograniczeń komunikacyjnych klastra.

Równoległe programowanie systemów rozproszonych tradycyjnie realizuje się za pomocą interfejsu przekazywania komunikatów (ang. *Message Passing Interface*, MPI), co daje wysoką wydajność kosztem znacznej złożoności kodu: programista jawnie zarządza podziałem danych, buforami wymiany oraz synchronizacją [11]. Alternatywę oferują języki i biblioteki oparte na modelu *PGAS* (ang. *Partitioned Global Address Space*, partycjonowana globalna przestrzeń adresowa) [8]. Język Chapel, rozwijany pierwotnie przez firmę Cray, jest jednym z bardziej rozwiniętych języków w tej grupie [1]. Umożliwia zapisywanie obliczeń rozproszonych w notacji zbliżonej do sekwencyjnej: z globalnym widokiem tablic, wysokopoziomowymi iteratorami równoległymi i gotowymi rozkładami dziedzin. Szczegóły komunikacji pozostawia warstwie wykonawczej, opartej na bibliotece GASNet.

Celem niniejszej pracy jest zaprojektowanie, zaimplementowanie i wdrożenie na klastrze rozproszonego programu symulującego równanie przewodnictwa ciepła w Chapel oraz analiza jego poprawności i skalowalności.

Rozdział 2

Problem i wykorzystane technologie

2.1 Równanie ciepła i metoda różnic skończonych

2.1.1 Model fizyczny

Rozważanym zjawiskiem fizycznym jest dyfuzja ciepła w jednorodnym, izotropowym ośrodku wypełniającym trójwymiarowy sześcian jednostkowy $\Omega = [0, 1]^3$. Pole skalarne $u(\mathbf{x}, t)$ opisuje temperaturę w punkcie $\mathbf{x} = (x, y, z) \in \Omega$ w chwili $t \geq 0$. Ewolucję tego pola opisuje równanie różniczkowe cząstkowe znane jako równanie przewodnictwa ciepła, zwane też równaniem dyfuzji:

$$\frac{\partial u}{\partial t} = \alpha \nabla^2 u = \alpha \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} + \frac{\partial^2 u}{\partial z^2} \right), \quad (2.1)$$


gdzie ∇^2 oznacza operator Laplace’a, natomiast $\alpha > 0$ to współczynnik dyfuzyjności cieplnej (ang. *thermal diffusivity*), wyrażony w jednostkach m^2/s . Wielkość α łączy przewodność cieplną ośrodka z jego pojemnością cieplną i gęstością; im większa jej wartość, tym szybciej lokalne różnice temperatury ulegają wygładzeniu. W zaimplementowanym programie przyjęto bezwymiarową wartość $\alpha = 0,25$ jako parametr konfiguracyjny.

2.1.2 Warunki początkowe i brzegowe

Rozwiązanie równania (2.1) jest jednoznaczne dopiero po zadaniu warunku początkowego oraz warunków brzegowych. W zaimplementowanym rozwiązaniu warunek początkowy przyjmuje jednorodne pole $u(\mathbf{x}, 0) = 1$ w całej dziedzinie, w którym umieszczono nagrzaną warstwę o grubości 2 płaszczyzn siatki (stała konfiguracyjna

hotThickness) przylegającą do ściany $y = 0$, o podwyższonej wartości $u = 2$. Warstwa ta modeluje gorącą ścianę, od której ciepło rozchodzi się w głąb sześcianu.

Na brzegu dziedziny przyjęto warunki Dirichleta o ustalonych wartościach: cała zewnętrzna warstwa komórek siatki nigdy nie jest aktualizowana i zachowuje swoje wartości początkowe przez cały czas symulacji. W praktyce oznacza to, że aktualizowane jest wyłącznie wnętrze dziedziny, a warstwa gorąca przy $y = 0$ pozostaje utrzymywana na poziomie $u = 2$, pełniąc rolę stałego źródła ciepła. Pozostałe ściany, utrzymywane na poziomie $u = 1$, działają jak zbiorniki ciepła o ustalonej temperaturze. Taki dobór warunków daje pole, które monotonnie ewoluuje i z czasem dąży do stanu ustalonego, z gradientem między gorącą a zimnymi ścianami. Rysunek 2.1 ilustruje jakościowo charakter tej ewolucji na dwuwymiarowym przykładzie: podtrzymywane źródło ciepła stopniowo traci ostre krawędzie, a ciepło rozchodzi się w otoczenie. Należy zaznaczyć, że dla czytelności wizualnej ilustracja ta posługuje się źródłem ciepła w kształcie grzebienia w przestrzeni dwuwymiarowej, które ukazuje ten sam mechanizm rozchodzenia się ciepła, lecz w układzie innym niż trójwymiarowa gorąca ściana rozważana w niniejszej pracy.



Rysunek 2.1: Ewolucja pola temperatury w dwuwymiarowej symulacji dyfuzji, wykonana dwuwymiarowym programem Chapel (dziedzina 160×160). Od lewej: początkowe, podtrzymywane źródło ciepła w kształcie grzebienia, a następnie stopniowe wygładzanie ostrych szczegółów i propagacja ciepła w otoczenie, aż do ukształtowania się gładkiego gradientu. Barwa odwzorowuje temperaturę: błękit oznacza zimno, czerwień gorąco. Ta sama zasada obowiązuje w przypadku trójwymiarowym rozważanym w pracy.

2.1.3 Dyskretyzacja: jawna metoda różnic skończonych

Do rozwiązania równania (2.1) zastosowano jawną metodę różnic skończonych (ang. *Finite Difference Method*, FDM) z jawnym schematem Eulera w czasie i centralnymi różnicami drugiego rzędu w przestrzeni [12, 13]. Dziedzinę ciągłą zastępuje się regularną siatką kartezjańską o $n_x \times n_y \times n_z$ węzłach. Krok siatki w każdym z kierunków dobrany jest tak, aby węzły skrajne pokrywały się z brzegiem sześcianu

jednostkowego:

$$\Delta x = \frac{1}{n_x - 1}, \quad \Delta y = \frac{1}{n_y - 1}, \quad \Delta z = \frac{1}{n_z - 1}. \quad (2.2)$$

Wartość pola w węźle (i, j, k) w kroku czasowym n oznacza się przez $u_{i,j,k}^n$. Do przybliżenia pierwszej pochodnej czasowej użyto ilorazu różnicowego przedniego, a drugich pochodnych przestrzennych standardowych trzypunktowych ilorazów centralnych, na przykład dla kierunku x :

$$\frac{\partial^2 u}{\partial x^2}(x_i, y_j, z_k) \approx \frac{u_{i-1,j,k}^n - 2u_{i,j,k}^n + u_{i+1,j,k}^n}{(\Delta x)^2}, \quad (2.3)$$

i analogicznie dla kierunków y oraz z . Podstawienie tych przybliżeń do (2.1) i rozwiązanie względem wartości w następnym kroku prowadzi do jawnej formuły aktualizacji.

Dla zwięzłości zapisu wprowadza się współczynniki wagowe zależne od osi, łączące dyfuzyjność, krok czasowy oraz krok siatki:

$$a_x = \frac{\alpha \Delta t}{(\Delta x)^2}, \quad a_y = \frac{\alpha \Delta t}{(\Delta y)^2}, \quad a_z = \frac{\alpha \Delta t}{(\Delta z)^2}. \quad (2.4)$$


Przy tych oznaczeniach regułę aktualizacji można zapisać jako siedmiopunktowy stencil (ang. *7-point stencil*):

$$\begin{aligned} u_{i,j,k}^{n+1} = & u_{i,j,k}^n + a_x (u_{i-1,j,k}^n - 2u_{i,j,k}^n + u_{i+1,j,k}^n) \\ & + a_y (u_{i,j-1,k}^n - 2u_{i,j,k}^n + u_{i,j+1,k}^n) \\ & + a_z (u_{i,j,k-1}^n - 2u_{i,j,k}^n + u_{i,j,k+1}^n). \end{aligned} \quad (2.5)$$

Nowa wartość w każdym węźle zależy wyłącznie od wartości w tym węźle oraz w jego sześciu bezpośrednich sąsiadach z poprzedniego kroku czasowego: dwóch wzdłuż każdej z trzech osi. Ten wzorzec dostępu do pamięci, komórka centralna plus sześć sąsiadów, przedstawiono na rysunku 2.2. Zależność od stanu wyłącznie z poprzedniego kroku jest cechą schematu jawnego i czyni każdy krok czasowy w pełni równoległym względem węzłów siatki.

2.1.4 Stabilność numeryczna i warunek CFL

Zaletą schematów jawnych jest prostota i niski koszt pojedynczego kroku: nie wymagają one rozwiązywania układów równań, w przeciwieństwie do schematów niejawnych. Ceną za tę prostotę jest jednak warunkowa stabilność: krok czasowy Δt nie może być dowolnie duży [12, 14]. Zbyt duży krok powoduje, że błędy zaokrą-



Rysunek 2.2: Siedmiopunktowy stencil trójwymiarowy. Nowa wartość w komórce centralnej $u_{i,j,k}$, zaznaczonej na niebiesko, jest ważoną kombinacją jej wartości bieżącej oraz sześciu bezpośrednich sąsiadów zaznaczonych na czerwono, wzdłuż osi x , y i z , zgodnie z równaniem (2.5).

gleń i składowe wysokoczęstotliwościowe rozwiązania numeryczne są wzmacniane w każdej iteracji zamiast tłumione, co prowadzi do gwałtownej, нефизycznej rozbieżności rozwiązania.

Analiza stabilności metodą von Neumanna [13, 12], polegająca na rozłożeniu błędu na składowe falowe i śledzeniu ich ewolucji krok po kroku, zastosowana dla schematu jawnego równania dyfuzji w trzech wymiarach prowadzi do warunku Couranta–Friedrichsa–Lewy’ego (CFL). Dla liniowego schematu o stałych współczynnikach współczynnik wzmocnienia pojedynczego modu Fouriera, określający, ile razy amplituda tego modu rośnie lub maleje w jednym kroku, wynosi

$$g = 1 - 4a_x \sin^2(\theta_x/2) - 4a_y \sin^2(\theta_y/2) - 4a_z \sin^2(\theta_z/2), \quad (2.6)$$

a żądanie $|g| \leq 1$ dla najbardziej niekorzystnego modu o naprzemiennym znaku między sąsiednimi węzłami redukuje się do nierówności $a_x + a_y + a_z \leq \frac{1}{2}$: sumaryczna waga dyfuzyjna nie może przekraczać jednej drugiej, co wyznacza maksymalny dopuszczalny krok czasowy:

$$\Delta t_{\max} = \frac{1}{2\alpha \left(\frac{1}{(\Delta x)^2} + \frac{1}{(\Delta y)^2} + \frac{1}{(\Delta z)^2} \right)}. \quad (2.7)$$

Zależność (2.7) ma praktyczne konsekwencje: dwukrotne zagęszczenie siatki wymusza czterokrotne zmniejszenie kroku czasowego, a więc czterokrotny wzrost liczby kroków potrzebnych do przebycia tego samego przedziału czasu fizycznego. Wraz z ośmiokrotnym wzrostem liczby węzłów siatki daje to duży wzrost całkowitego nakładu obliczeniowego, co jest jedną z przyczyn, dla których symulacje dużych siatek wymagają obliczeń rozproszonych.

W zaimplementowanym programie krok czasowy dobierany jest automatycznie na podstawie warunku (2.7), z zastosowaniem współczynnika bezpieczeństwa 0,98:

$$\Delta t = 0,98 \cdot \Delta t_{\max}. \quad (2.8)$$

Ten 2 % margines (ang. *safety back-off*) przesuwą punkt pracy poniżej granicy stabilności, do $g = -0,96$ dla najbardziej niekorzystnego modu; wartość ujemna jest dopuszczalna, gdyż warunek stabilności wymaga jedynie $|g| \leq 1$, a ujemne g oznacza, że dany mod zmienia znak co krok, lecz nie rośnie w amplitudzie. Dzięki temu schemat pozostaje stabilny nawet przy błędach zaokrągleń arytmetyki zmiennoprzecinkowej i drobnych efektach numerycznych, które mogłyby zepchnąć krok dokładnie na granicy w obszar niestabilności. Wartość bliska jedności jest też korzystna wydajnościowo: maksymalizuje postęp w czasie fizycznym na jeden krok i zmniejsza liczbę wymian danych między węzłami, o których mowa w dalszej części rozdziału.


2.2 Zrównoleglenie obliczeń stencilowych

2.2.1 Dekompozycja dziedziny i komórki brzegowe

Obliczenia stencilowe należą do klasy problemów zrównoleglanych przez podział danych (ang. *data parallelism*). Ponieważ aktualizacja każdego węzła według (2.5) jest niezależna w obrębie jednego kroku czasowego, naturalną strategią jest dekompozycja dziedziny (ang. *domain decomposition*): globalna siatka zostaje podzielona na rozłączne podobszary, z których każdy przypisany jest do osobnej jednostki obliczeniowej, w rozważanym przypadku do osobnego węzła klastra. Każdy węzeł oblicza aktualizację wyłącznie dla przydzielonych mu komórek.

Problem pojawia się na granicach podobszarów. Aby zaktualizować komórki leżące tuż przy krawędzi swojego podobszaru, węzeł potrzebuje wartości sąsiadów znajdujących się już w podobszarze sąsiedniego węzła. Rozwiązaniem jest otoczenie każdego lokalnego podobszaru dodatkową warstwą komórek brzegowych (ang. *ghost cells* lub *halo*), które przechowują kopie wartości z krawędzi sąsiednich podobszarów. W terminologii Chapel warstwa ta nosi nazwę *fluff*; w zaimplementowanym programie zadeklarowano ją o grubości jednej komórki w każdym kierunku,

$fluff=(1,1,1)$, co odpowiada zasięgowi siedmiopunktowego stencila. Rysunek 2.3 przedstawia schematycznie podział dziedziny na podobszary wraz z warstwami brzegowymi.



Rysunek 2.3: Dekompozycja dziedziny w postaci plastrów (ang. *slab decomposition*) na trzy jednostki (*locale*). Globalna siatka jest cięta wzdłuż jednej osi, którą wskazuje strzałka na dole; każdy podobszar, zaznaczony na niebiesko, otoczony jest warstwą komórek brzegowych *fluff*, zaznaczoną na czerwono linią przerywaną, przechowującą kopie krawędzi sąsiadów. Przed każdym krokiem obliczeń wywołanie `updateFluff()` realizuje wymianę brzegów z najbliższymi sąsiadami.

2.2.2 Wymiana brzegów jako jedyna komunikacja

W każdym kroku czasowym warstwy brzegowe muszą zostać odświeżone, zanim rozpocznie się faza obliczeń, gdyż przechowywane w nich wartości pochodzą z poprzedniego kroku sąsiedniego węzła. Ta wymiana danych z najbliższymi sąsiadami (ang. *nearest-neighbour* lub *halo exchange*) jest jedynym rodzajem komunikacji między węzłami wymagany przez schemat jawny. W zaimplementowanym programie realizuje ją pojedyncze wywołanie metody `updateFluff()` modułu rozkładów Chapel, wykonywane na początku każdego kroku, przed pętlą aktualizującą wnętrze dziedziny. Na więcej niż jednym lokalu wymiana ta jest obowiązkowa dla poprawności: jej pominięcie sprawia, że komórki otoczki zachowują wartości z poprzedniego kroku, przez co obliczenie przebiega szybciej, lecz daje wynik cicho błędny.

Prowadzi to do wyraźnego rozdzielenia każdego kroku czasowego na dwie fazy: fazę komunikacji, czyli odświeżenie warstw brzegowych, oraz fazę obliczeń, czyli wykonanie formuły (2.5) dla wszystkich komórek wnętrza. W programie fazy te są oddzielnie mierzone stoperami `fluffTimer` i `computeTimer`, co pozwala rozdzielić czas spędzony na komunikacji od czasu obliczeń. Struktura pojedynczego kroku

jest zwięźle widoczna w procedurze `stepOnce` (listing 3.9): najpierw synchronizacja brzegów, potem równoległa aktualizacja wnętrza.

2.2.3 Intensywność arytmetyczna i ograniczenia wydajności

Obliczenia stencilowe mają bardzo niską *intensywność arytmetyczną* (ang. *arithmetic intensity*) [16], czyli iloraz liczby wykonanych operacji zmiennoprzecinkowych do liczby bajtów przeniesionych z pamięci. Aktualizacja jednego węzła według (2.5) wymaga zaledwie kilkunastu operacji zmiennoprzecinkowych, sześciu odejmowań, trzech mnożeń przez wagi i kilku dodawań, a jednocześnie odczytu siedmiu wartości i zapisu jednej, przy 8 B na liczbę w podwójnej precyzji daje to zaledwie ułamek operacji na każdy przeniesiony bajt. Co więcej, sąsiednie węzły współdzielą większość odczytów, lecz nawet przy idealnym wykorzystaniu pamięci podręcznej stosunek ten pozostaje niski.

W efekcie wydajność obliczeń stencilowych ogranicza nie moc procesora, lecz przepustowość transferu danych. W ujęciu modelu *roofline* [15], który wyznacza górną granicę wydajności na podstawie intensywności arytmetycznej zadania oraz przepustowości pamięci, punkt pracy obliczeń stencilowych leży w obszarze ograniczonym przepustowością pamięci, a nie szczytową wydajnością obliczeniową. Na pojedynczym węźle oznacza to ograniczenie przepustowością pamięci (ang. *memory-bandwidth bound*): dodawanie kolejnych rdzeni obliczeniowych przynosi coraz mniejsze korzyści, gdy magistrala pamięci ulega nasyceniu. W obliczeniach rozproszonych, gdzie warstwy brzegowe muszą przejść przez sieć, zadanie staje się ograniczone komunikacją (ang. *communication bound*): o całkowitym czasie decyduje przepustowość i opóźnienie połączeń sieciowych między węzłami, a nie szybkość samych obliczeń.

Zależność ta ma jednak korzystną stronę. Objętość obliczeń w podobszarze rośnie proporcjonalnie do jego objętości, czyli jak N^3 dla sześcianu o boku N , podczas gdy objętość danych brzegowych podlegających wymianie rośnie proporcjonalnie do pola powierzchni granic, czyli jak N^2 . Stosunek nakładu obliczeń do nakładu komunikacji jest zatem rzędu $N^3/N^2 = N$ i rośnie liniowo z rozmiarem krawędzi siatki. Większe sześciany mają zatem korzystniejszy stosunek obliczeń do komunikacji, bo koszt komunikacji zostaje zamortyzowany większą liczbą obliczeń przypadających na każdy przesłany bajt. Wynik ten sprawdzono empirycznie w rozdziale z wynikami.

2.2.4 Miary skalowalności

Do ilościowej oceny efektywności zrównoleglenia stosuje się standardowy aparat pojęciowy. *Przyspieszenie* (ang. *speedup*) przy użyciu p jednostek obliczeniowych definiuje się jako stosunek czasu wykonania programu na jednej jednostce do czasu

wykonania tego samego programu na p jednostkach:

$$S(p) = \frac{T(1)}{T(p)}, \quad (2.9)$$

a efektywność równoległą (ang. *parallel efficiency*) jako przyspieszenie znormalizowane liczbą jednostek:

$$E(p) = \frac{S(p)}{p} = \frac{T(1)}{pT(p)}. \quad (2.10)$$

Idealne, liniowe przyspieszenie odpowiada $S(p) = p$ oraz $E(p) = 1$; w praktyce narzuty komunikacji, synchronizacji i nierównomiernego obciążenia sprawiają, że $E(p) < 1$, przy czym efektywność zwykle maleje ze wzrostem p .

Wyróżnia się dwa rodzaje skalowania. *Skalowanie silne* (ang. *strong scaling*) polega na ustaleniu całkowitego rozmiaru problemu i zwiększaniu liczby jednostek obliczeniowych; celem jest skrócenie czasu rozwiązania. Przy tym skalowaniu udział pracy przypadającej na jednostkę maleje, przez co narzuty komunikacyjne stają się względnie coraz istotniejsze. *Skalowanie słabe* (ang. *weak scaling*) polega na ustaleniu rozmiaru problemu przypadającego na jedną jednostkę i proporcjonalnym zwiększaniu zarówno liczby jednostek, jak i całkowitego rozmiaru problemu; celem jest rozwiązywanie coraz większych zadań w stałym czasie.

Fundamentalne ograniczenie skalowania silnego formułuje *prawo Amdahla* [17]. Jeśli f oznacza sekwencyjną część obliczeń, której z natury nie da się zrównoleglić, to maksymalne osiągalne przyspieszenie przy p jednostkach wynosi

$$S(p) \leq \frac{1}{f + \frac{1-f}{p}}, \quad \lim_{p \rightarrow \infty} S(p) = \frac{1}{f}. \quad (2.11)$$

Nawet niewielki udział części sekwencyjnej narzuca twardą górną granicę przyspieszenia, niezależnie od liczby dostępnych jednostek. W kontekście rozważanego programu rolę nieusuwalnego narzutu pełni głównie komunikacja, wymiana warstw brzegowych oraz synchronizacja między krokami, co, w połączeniu z ograniczeniem przepustowości pamięci i sieci omówionym wcześniej, wyznacza granice skalowalności, które badano w rozdziale z wynikami.

2.3 Chapel, PGAS i GASNet

2.3.1 Język Chapel i model PGAS

Implementację programu oparto na języku Chapel, języku programowania równoległego rozwijanym z naciskiem na wygodę programisty przy zachowaniu wysokiej

wydajności na systemach wieloprocessorowych i rozproszonych [1, 2]. Chapel realizuje model *PGAS* (ang. *Partitioned Global Address Space*, partycjonowana globalna przestrzeń adresowa) [8, 9]. Idea PGAS polega na tym, że pamięć wszystkich węzłów tworzy jedną logicznie wspólną przestrzeń adresową, która jest jednak podzielona na partycje o jawnie określonym powinowactwie do węzłów. Programista operuje na danych za pomocą jednolitej, globalnej perspektywy (ang. *global-view*), tak jakby były one lokalne, natomiast środowisko uruchomieniowe automatycznie tłumaczy dostępy do danych zdalnych na operacje komunikacji sieciowej. W ten sposób PGAS łączy wygodę programowania w pamięci wspólnej, typową dla modelu pamięci współdzielonej, z kontrolą rozmieszczenia danych, którą daje model przekazywania komunikatów.

Chapel nie jest jedynym językiem tej grupy. Poza nim model PGAS realizują m.in. UPC (ang. *Unified Parallel C*), rozszerzenie języka C o globalne wskaźniki, Co-Array Fortran z notacją współobrazów (ang. *co-arrays*), który wszedł do standardu Fortran 2008, a także języki projektowane od podstaw dla PGAS: X10 (IBM) i Fortress (Sun Microsystems). Rozwiązania te różnią się głównie składnią, modelem zadań i sposobem wyrażania lokalności; wspólne jest im oddanie programiście globalnego widoku danych przy jawnym oznaczaniu powinowactwa do węzłów [8, 9].

Centralnym pojęciem w Chapel jest *locale*, abstrakcja jednostki systemu dysponującej własną pamięcią oraz zdolnością do wykonywania obliczeń. W konfiguracji wielowęzłowej stosowanej w niniejszej pracy każdemu locale'owi odpowiada dokładnie jeden węzeł fizyczny klastra, w odwzorowaniu *jeden-do-jednego*. Wbudowana tablica `Locales` udostępnia wszystkie dostępne jednostki, a ich liczbę podaje stała `numLocales`. Dostęp do danych i przenoszenie obliczeń pomiędzy jednostkami wyraża się wprost, za pomocą konstrukcji `on`.

2.3.2 Iteratory równoległe i tablice globalne

Chapel oferuje dwa uzupełniające się rodzaje równoległości. Równoległość danych wyraża pętla `forall`, która zleca wykonanie ciała iteracji dla wszystkich elementów dziedziny współbieżnie, pozostawiając środowisku uruchomieniowemu podział pracy na zadania i przypisanie ich do wątków. W programie to właśnie pętla `forall` nad dziedziną wnętrza (listing 3.9) realizuje fazę obliczeń stencila. Gdy pętla iteruje po dziedzinie rozproszonej, jej iteracje wykonują się na tych węzłach, do których przypisane są odpowiednie elementy, co zapewnia lokalność obliczeń bez jawnego zarządzania nią przez programistę.

Równoległość zadaniową między węzłami wyraża konstrukcja `coforall ... on loc`, która tworzy osobne zadanie dla każdego locale i umieszcza jego wykonanie na odpowiednim węźle. W programie wzorzec ten wykorzystywany jest między in-

nymi do równoległego zapisu klatek wynikowych: każdy węzeł niezależnie zapisuje swój lokalny podobszar. Listing 2.1 ilustruje ten idiom.

```
1 coforall loc in Locales do on loc {  
2   const ld = field.localSubdomain(); // lokalny fragment tablicy  
   globalnej  
3   var block: [ld] real = field[ld]; // kopia danych bez  
   komunikacji zdalnej  
4   // ... zapis / obliczenia lokalne na fragmencie ...  
5 }
```

Listing 2.1: Równoległość zadaniowa między węzłami: każdy locale wykonuje operację na swoim lokalnym podobszarze danych.

Tablice w Chapel definiowane są nad *dziedzinami* (ang. *domain*), obiektami opisującymi zbiór indeksów. Aby tablica została rozproszona pomiędzy węzły, jej dziedzinę wyposaża się w *odwzorowanie dziedziny* (ang. *domain map*, dystrybucję). Najprostszą dystrybucją jest **Block**, dzieląca zakres indeksów na w przybliżeniu równe, przylegające bloki i przypisująca je kolejnym węzłom. Na potrzeby obliczeń stencilowych Chapel udostępnia wyspecjalizowaną dystrybucję **Stencil** z modułu **StencilDist**, która poza podziałem danych utrzymuje opisaną wcześniej warstwę *fluff* i odświeża ją jawnym wywołaniem `updateFluff()` [4]. W programie dziedzinę tworzy się wywołaniem `stencilDist.createDomain(..., fluff=(1,1,1))`, ustalając grubość otoczki na jedną komórkę w każdym kierunku zgodnie z zasięgiem stencilu (2.5).

2.3.3 Konstrukcje równoległości i synchronizacja

Oprócz pętli `forall` i konstrukcji `coforall...on` Chapel udostępnia pomocnicze mechanizmy równoległości i synchronizacji, które pozwalają wyrażać wzorce nie dające się zapisać samym podziałem danych.

Równoległość na poziomie instrukcji realizują `begin` i `cobegin`. Instrukcja `begin` uruchamia pojedyncze zadanie w tle i nie blokuje dalszego wykonywania bieżącego wątku, a `cobegin` wykonuje każde z podanych zdań równoległe i czeka na zakończenie ich wszystkich. Pozwala to na zagnieżdżanie zadań i tworzenie struktur, w których kilka operacji przeplata się w czasie. Listing 2.2 ilustruje ten idiom.

```

1 cobegin {
2   writeTask();    // zadanie A
3   readTask();     // zadanie B, wykonuje sie rownolegle z A
4 }
5 // oba zadania konczą się zanim sterowanie przejdzie dalej

```

Listing 2.2: Równoległe uruchamianie zadań za pomocą `cobegin`.

Konstrukcja `on` przenosi wykonanie instrukcji na wskazany locale; wewnątrz bloku słowo kluczowe `here` oznacza bieżący locale, co pozwala odczytać jego właściwości bez jawnego odwoływania się do elementów tablicy `Locales`. Listing 2.3 pokazuje ten idiom.

```

1 on Locales[1] do
2   writeln("dzialam na: ", here.id, " z ", here.maxTaskPar, "
   watkami");

```

Listing 2.3: Przeniesienie wykonania na konkretny locale z użyciem `here`.

Do synchronizacji producenta z konsumentem służą zmienne `single` (tak zwane zmienne synchronizujące): zapis do takiej zmiennej wstrzymuje wykonanie, dopóki nie zostanie odczytana, a odczyt wstrzymuje je, dopóki nie zostanie zapisana. Dają one semantykę jednorazowego przekazania wartości między zadaniami bez jawnych zamków (ang. *locks*). Listing 2.4 przedstawia ten mechanizm.

```

1 var s: single int;           // zmienna synchronizujaca
2 begin { s = computeResult(); } // producent
3 const v = s;                 // konsument czeka na wartosc

```

Listing 2.4: Zmienna synchronizująca jako kanał jednorazowy między zadaniami.

Dla bezpiecznej manipulacji stanem współdzielonym Chapel udostępnia typy `atomic`, które gwarantują niepodzielność operacji odczytu, zapisu i dodawania. Typowe zastosowanie to liczniki globalne, sumy częściowe i sekwencjonowanie dostępu do zasobów, bez ryzyka wyścigu. Listing 2.5 pokazuje typowe użycie.

```

1 var counter: atomic int;
2 counter.add(1);           // atomowe dodawanie
3 const n = counter.read(); // atomowy odczyt

```

Listing 2.5: Operacje atomowe na liczniku współdzielonym.

Wreszcie, dla typowych operacji redukcyjnych Chapel oferuje wyrażenia redukcji, które pozwalają zredukować tablicę lub pętlę do pojedynczej wartości przy użyciu operatorów takich jak `+`, `min` czy `max`, przy czym samo dzielenie pracy i akumula-

cja wyniku pozostają w rękach środowiska uruchomieniowego. Listing 2.6 ilustruje redukcję sumy.

```
1 var s = + reduce A;
```

Listing 2.6: Suma wszystkich elementów tablicy A.


2.3.4 Warstwa zadań `qthreads` oraz warstwa komunikacji GASNet

Wykonywanie zadań w obrębie pojedynczego locale obsługuje scheduler zadań. W zastosowanej konfiguracji jest to biblioteka `qthreads` (`CHPL_TASKS=qthreads`), lekki system wątków użytkownika efektywnie obsługujący dużą liczbę drobnoziarnistych (ang. *fine-grained*) zadań generowanych przez pętle `forall` [5]. Liczbę wątków sprzętowych dostępnych na danym węźle udostępnia własność `here.maxTaskPar`; wyznacza ona stopień równoległości fazy obliczeń w obrębie węzła; jest to liczba wątków obliczeniowych na lokal, a nie liczba lokali, i jest raportowana przez program przy starcie.

Za komunikację między węzłami odpowiada z kolei warstwa *GASNet*, przenośna biblioteka uruchomieniowa dostarczająca podstawowych operacji komunikacji jednostronnej (ang. *one-sided*) oraz komunikatów aktywnych, na których Chapel opiera realizację dostępu do pamięci zdalnej i operacji `on` [6, 7]. Uaktywnia się ją ustawieniem `CHPL_COMM=gasnet`. W zastosowanej konfiguracji przyjęto tryb segmentu `CHPL_GASNET_SEGMENT=everything`, w którym cała pamięć procesu jest udostępniana dla komunikacji zdalnej, co upraszcza rozmieszczanie tablic rozproszonych. Warstwową strukturę całego stosu, od kodu aplikacji, przez model globalnej tablicy PGAS, aż po sprzęt sieciowy, przedstawia rysunek 2.4.

2.3.5 Kanały komunikacyjne GASNet

GASNet abstrahuje sprzęt sieciowy poprzez wymienne *kanały komunikacyjne* (ang. *conduits*), moduły implementujące operacje komunikacji na konkretnej technologii transportu. W ramach niniejszej pracy porównywano dwa kanały komunikacyjne dostępne na klastrze zbudowanym z węzłów połączonych zwykłą siecią Ethernet. Kanał `udp`, oparty na warstwie AMUDP (ang. *Active Messages over UDP*), realizuje komunikację po protokole UDP i jest uruchamiany za pomocą programu rozruchowego `amudprun`. Jego zaletą jest prosta konfiguracja, a wadą podatność na przeciążenie przy intensywniej, drobnoziarnistej (ang. *fine-grained*) wymianie danych. Kanał `mpi` przenosi komunikację GASNet na istniejącą implementację MPI,



Rysunek 2.4: Warstwowa architektura wykonania. Kod aplikacji operuje na globalnych tablicach PGAS języka Chapel; ich dostępy zdalne i wymiana warstw brzegowych są realizowane przez warstwę uruchomieniową, w której zadania `qthreads` wykonują się lokalnie, a komunikacja `GASNet` zachodzi między węzłami; warstwa ta korzysta z kolei z wybranego kanału komunikacyjnego odwzorowującego operacje na fizyczną sieć klastra.

w zastosowanej konfiguracji opartej na MPICH nad TCP, i jest uruchamiany programem `gasnetrun_mpi`; zapewnia on stabilniejszy i wydajniejszy transport dla podtrzymywanych, regularnych wzorców komunikacji, jakie generuje cykliczna wymiana warstw brzegowych w opisywanym programie.

Wybór kanału komunikacyjnego ma istotne znaczenie dla rozproszonej symulacji. Jak wykazano w podrozdziale 2.2, przy skalowaniu na wiele węzłów zadanie jest ograniczone komunikacją, a jedyną komunikacją w kroku jest wymiana *halo* realizowana przez `updateFluff()`. O osiągniętej skalowalności decydują w praktyce właściwości warstwy komunikacyjnej: przepustowość, opóźnienie i odporność na przeciążenie. Dlatego dobór kanału komunikacyjnego jest jednym z głównych pytań badawczych w tej pracy.

Rozdział 3

Klaster i implementacja


3.1 Architektura klastra i środowisko

3.1.1 Sprzęt i topologia

Docelowym środowiskiem uruchomieniowym jest rzeczywisty klaster *Pionier*¹ w pracowni komputerowej Wydziału Matematyki i Informatyki UMK, złożony z dziewięciu jednorodnych węzłów fizycznych (*Pionier-lab8-1* ... *Pionier-lab8-9*) połączonych przełącznikiem Ethernet o przepustowości 1 Gb/s. Wszystkie węzły są identyczne: każdy wyposażony jest w procesor Intel Core i7-12700K (12 rdzeni, 20 wątków sprzętowych), 32 GiB pamięci RAM DDR4-3200 oraz kartę sieciową Intel I219-V (sterownik `e1000e`, 1 Gb/s) i pracuje pod systemem Ubuntu (jądro `6.8.0-111-generic`). Węzły mają adresy z podsieci `192.168.128.0/24`, a dostęp do nich odbywa się bezpośrednim poleceniem `ssh <ip>`. Jednorodność środowiska, czyli ta sama architektura procesora, dystrybucja i wersja bibliotek na każdym węźle, upraszcza dystrybucję plików wykonywalnych: obraz zbudowany na jednym węźle działa bez zmian na pozostałych. W eksperymentach skalowania każdemu lokalowi (*locale*) odpowiadał jeden węzeł fizyczny, co pozwoliło zbadać skalowanie w funkcji liczby węzłów aż do dziewięciu.

Topologię środowiska przedstawiono na rysunek 3.1. Wszystkie węzły dzielą jedno łącze o przepustowości 1 Gb/s, które jest wąskim gardłem komunikacji rozproszonej, bo każda wymiana komórek brzegowych między sąsiednimi fragmentami dziedziny przechodzi przez ten sam przełącznik.

¹Klaster został zakupiony w ramach projektu PIONIER-LAB (nr POIR.04.02.00-30-A005/16) sfinansowanego przez Unię Europejską w ramach Funduszy Europejskich Programu Operacyjnego Inteligentny Rozwój.



Rysunek 3.1: Topologia jednorodnego, dziewięciowęzłowego klastra Pionier. Wszystkie identyczne węzły (*Pionier-lab8-1* ... *Pionier-lab8-9*) połączone są jednym przełącznikiem 1 Gb/s, który stanowi współdzielone i zarazem najwęższe łącze komunikacji rozproszonej. Środowisko budowane jest raz na dowolnym węźle, a pliki wykonywalne rozprowadzane na pozostałe.

3.1.2 Konfiguracja kompilatora Chapel

Kompilator Chapel w wersji 2.9.0 zbudowano ze źródeł na jednym węźle [3]. Kluczowe parametry środowiska są *zapięzione* (ang. *baked in*) w pliku `chplconfig`, który skrypt `distribute-chapel.sh` zapisuje jeszcze przed wywołaniem `make`. Dzięki temu każdy węzeł otrzymuje pliki wykonywalne zbudowane z identyczną konfiguracją. Zawartość istotnej części pliku konfiguracyjnego przedstawia listing 3.1.

```

1 CHPL_COMM=gasnet
2 CHPL_COMM_SUBSTRATE=$CONDUIT          # udp (domyslnie) albo mpi
3 CHPL_LLVM=none                        # backend C, nie LLVM
4 CHPL_TARGET_CPU=$TARGET_CPU           # native

```

Listing 3.1: Fragment pliku `chplconfig` generowanego przed budową kompilatora.

Warstwą komunikacyjną jest GASNet (`CHPL_COMM=gasnet`), co umożliwia pracę wielolokalową. Kompilacja odbywa się z użyciem backendu C (`CHPL_LLVM=none`) zamiast LLVM, co pozwala uniknąć zależności od bibliotek programistycznych LLVM na każdym węźle i upraszcza dystrybucję jednorodnego drzewa Chapel. Ustawienie `CHPL_TARGET_CPU=native` pozwala na generowanie kodu wykorzystującego pełen zestaw instrukcji procesora hosta; jest to bezpieczne wyłącznie dlatego, że produkcyjny klaster jest jednorodny pod względem architektury procesorów. Z konfiguracji wynikają dalsze, domyślne wartości środowiska: `CHPL_TASKS=qthreads`, `CHPL_GASNET_SEGMENT=everything`, `CHPL_LOCALE_MODEL=flat` oraz `CHPL_TARGET_MEM=jemalloc`. Program startowy zależy od wybranego kanału komunikacyjnego i przyjmuje wartość `amudprun` dla kanału `udp` albo `gasnetrun_mpi` dla kanału `mpi`.

3.1.3 Dwa kanały komunikacyjne GASNet

Warstwę GASNet można zbudować na dwóch różnych kanałach transportowych (*conduit*), wybieranych parametrem `--conduit` [7]. Kanał **udp** realizuje protokół AMUDP nad UDP; nie ma dodatkowych zależności i jest szybki w czystej sieci lokalnej, jednak przy dużej skali załamuje się z błędem `ECONGESTION` w sytuacji wielu-do-jednego (*incast*) oraz przy utracie pakietów [18]. Kanał **mpi** realizuje GASNet mpi-conduit za pośrednictwem biblioteki MPICH w trybie `ch3:sock` (zwykły TCP), którego mechanizm kontroli przepływu zapewnia odporność na utratę pakietów i zjawisko incast [10, 11]. Ze względu na to, że wybór kanału zapisany jest w pliku `chplconfig`, dla każdego kanału utrzymywane jest osobne, w pełni skompilowane drzewo Chapel (ścieżki `.../chapel` oraz `.../chapel-mpi`).

Biblioteka MPICH w wersji 4.2.3 została zbudowana ze źródeł skryptem `build-mpi.sh` do prefiksu niewymagającego uprawnień administratora, z linią konfiguracji przedstawioną w listingu 3.2. Budowa ze źródeł zapewnia na każdym węźle *identyczną* wersję i konfigurację MPI, w szczególności urządzenie `ch3:sock` (zwykły TCP), którego kontroli przepływu nie gwarantują gotowe pakiety systemowe, dostarczające zwykle OpenMPI w domyślnej konfiguracji.

```
1 ./configure --prefix=$PREFIX --disable-fortran \  
2 --with-device=ch3:sock --disable-static
```

Listing 3.2: Linia konfiguracji budowy MPICH ze źródeł.

3.1.4 Uruchamianie i samoopisujące się logi

Dla każdego pliku wykonywalnego skrypt `compile-and-distribute.sh` (funkcja `gen_run_script`) generuje osobny skrypt uruchomieniowy. Ustawia on zmienne `CHPL_HOME` oraz `PATH`, domyślnie przyjmuje liczbę wątków na lokal równą `$(nproc)`, a przebieg rejestruje do logu o nazwie zawierającej znacznik czasu (`logs/<bin>-YYYYmmdd-HHMMSS.log`). Zasadniczy fragment logiki uruchomieniowej pokazano w listingu 3.3.

```
1 set -o pipefail  
2 {  
3     echo "[cfg] threadsPerLocale(requested)=  
4         $CHPL_RT_NUM_THREADS_PER_LOCALE numLocales=${NUM_LOCALES}"  
5     ./${bin} -nl ${NUM_LOCALES} "$@" 2>&1  
6 } | tee "$LOG"
```

Listing 3.3: Blok uruchomieniowo-rejestrujący ze skryptu wrappera.

Log jest samoopisujący dzięki dwóm liniom [cfg]. Pierwsza, pochodząca ze skryptu, ma postać [cfg] `threadsPerLocale(requested)=N numLocales=M` i podaje wartości *żądane*. Druga, pochodząca z programu, ma postać [cfg] `locale <id> maxTaskPar=<n>` i podaje *efektywną* liczbę wątków na lokal po ograniczeniu jej przez qthreads do możliwości sprzętu [5]. Rozróżnienie to jest istotne przy analizie wydajności, ponieważ w przypadku nadsubskrypcji (*oversubscription*) liczba żądana może przewyższać liczbę faktycznie dostępnych rdzeni. Konfiguracja programu startowego zależy od kanału: dla mpi ustawiane jest `MPIRUN_CMD="mpirun -n %N -hosts <hosts> <install>/mpi-iface-wrap.sh %C"`, natomiast dla udp, zmienne `GASNET_SSH_SERVERS` oraz `GASNET_MASTERIP`.

Do celowego wywoływania obciążenia sieci służy skrypt `run-nl.sh`. Przeplata on listę serwerów SSH tak, że kolejne lokale trafiają na różne węzły fizyczne, przez co sąsiadujące fragmenty dziedziny w rozkładzie `StencilDist` znajdują się na różnych węzłach. W konsekwencji *każda* operacja pobrania halo przekracza wspólne łącze 1 Gb/s, tworząc celowe obciążenie typu incast, które obnaża ograniczenia kanału udp.

Ostatnim elementem środowiska jest skrypt `mpi-iface-wrap.sh` odpowiedzialny za przypięcie interfejsu sieciowego per ranga na węzłach wielosieciowych. Wybiera on lokalny adres IPv4 z właściwej podsieci klastra (192.168.128.0/24), pomijając interfejsy wirtualne, czyli mostki `docker0` i `virbr0`, podsieci 172.16/12 oraz adresy libvirt 192.168.122.*, eksportuje `MPICH_INTERFACE_HOSTNAME`, po czym uruchamia program. Bez tego kroku transport `ch3:sock` może rozgłosić nieroutowalny adres interfejsu, a wywołanie `MPI_Init` kończy się błędem „No route to host”.

3.1.5 Procedura wdrożenia krok po kroku

Elementy opisane w poprzednich podrozdziałach tworzą procedurę wdrożenia, od zbudowania środowiska aż po uruchomienie przebiegu. Choć węzły są jednorodne, procedura ta wykracza poza zwykłą kompilację lokalną, ponieważ kolejność kroków oraz miejsce ich wykonania są istotne dla poprawności i wymagają spójnych ścieżek oraz identycznych drzew Chapel i MPICH na wszystkich węzłach. Całość podzielono na cztery etapy.

W *pierwszym etapie* na dowolnie wybranym węźle budowane jest środowisko wykonawcze: kompilator Chapel w wersji 2.9.0 (skrypcem `distribute-chapel.sh`) oraz biblioteka MPICH w wersji 4.2.3 w trybie `ch3:sock` (skrypcem `build-mpi.sh`); wybór węzła jest dowolny dzięki jednorodności klastra.

W *drugim etapie* skompilowane drzewo Chapel jest pakowane do archiwum i rozsyłane pod *identyczną* ścieżkę bezwzględną na każdym węźle (listing 3.4). Identyfikacja tej ścieżki jest drugim niezmiennikiem całej procedury: warstwa urucho-

mieniowa Chapel jest kompilowana ze ścieżką `rpath` wskazującą wprost do drzewa `CHPL_HOME`, więc jakakolwiek rozbieżność lokalizacji uniemożliwia dynamiczne odnalezienie bibliotek współdzielonych. Analogicznie, jedno drzewo MPICH zbudowane raz jest strumieniowane pod tę samą ścieżkę na wszystkich węzłach, co gwarantuje zgodność ABI wymaganą przez `mpi-conduit`.

```
1 tar czf chapel-2.9.0-built.tar.gz -C "$CHPL_HOME/.." chapel-2.9.0
2 for h in $HOSTS; do
3     scp chapel-2.9.0-built.tar.gz "$h:$DEST/"
4     ssh "$h" "tar xzf $DEST/chapel-2.9.0-built.tar.gz -C $DEST"
5 done
```

Listing 3.4: Spakowanie i rozesłanie zbudowanego drzewa pod identyczną ścieżkę.

W *trzecim etapie* kompilowany jest sam program i rozprowadzany na węzły skryptem `compile-and-distribute.sh`. Dla każdego programu kopiowane są *zarówno* plik startowy `<bin>`, jak i właściwy obraz wykonywalny `<bin>_real`; oba są niezbędne na każdym węźle do uruchomienia wielolokalowego. Skrypt generuje przy tym dedykowany skrypt uruchomieniowy (por. listing 3.3), który ustawia `CHPL_HOME` i `PATH` zgodnie z rozesłanym drzewem.

W *czwartym etapie* przebieg uruchamiania jest przez wygenerowany skrypt uruchomieniowy, który wywołuje właściwy program startowy GASNet (`gasnetrun_mpi` dla kanału `mpi` albo `amudprun` dla kanału `udp`) i rozdziela lokale na węzły. Dwa niezmienniki z poprzednich etapów, *identyczna ścieżka* `CHPL_HOME` (`rpath`) oraz *identyczne drzewa* *Chapel* i *MPICH* pod tą samą ścieżką na wszystkich węzłach, są warunkami koniecznymi powodzenia tego etapu. Naruszenie któregośkolwiek objawia się dopiero przy ładowaniu bibliotek lub starcie procesów zdalnych, czyli już po udanej kompilacji.

3.1.6 Uruchamianie eksperymentu

Procedurę pomiarową obsługują trzy skrypty generowane na węźle głównym. Skrypt `compile-and-distribute.sh` kompiluje program z wybranego conduitem, rozprowadza pliki wykonywalne na węzły z pliku `hostfile` i tworzy na miejscu dwa dalsze skrypty: uruchomieniowy `run-heat3d.sh` oraz agregujący `aggregate-heat3d.sh`. Sam skrypt nie buduje kompilatora Chapel ani biblioteki MPICH: zakłada, że ich drzewa zostały uprzednio zbudowane i leżą pod tą samą ścieżką na każdym węźle (tworzą je skrypty `distribute-chapel.sh` oraz `build-mpi.sh`). Wynikowe pliki wykonywalne mają wbudowany `rpath` wskazujący na to drzewo, dlatego musi ono istnieć pod identyczną ścieżką na każdym węźle. Ten pierwszy wywołuje właściwy program z ustawionym środowiskiem Chapel i GASNet, przekazując mu swoje ar-

gumenty jako parametry `config` programu (patrz tabela 3.2); liczbę lokacji zapisuje w sobie na etapie generowania, zaś liczbę wątków na lokal ustala zmienna `CHPL_RT_NUM_THREADS_PER_LOCALE`. Skrypt agregujący zbiera rozproszone zrzuty klatek na węzeł główny i uruchamia post-procesor `aggregate3d.chpl`, opcjonalnie renderując film.

Kluczowe flagi skryptu `compile-and-distribute.sh` zestawiono w tabeli 3.1. Pełną listę podaje opcja `--help`.

Tabela 3.1: Wybrane flagi skryptu `compile-and-distribute.sh`.

Flaga	Wartość domyślna	Znaczenie
<code>-f, --hostfile</code>	— (wymagane)	plik z adresami węzłów, master jako pierwszy
<code>-c, --conduit</code>	<code>udp</code>	kanał transportu: <code>udp</code> lub <code>mpi</code>
<code>-d, --dir</code>	<code>/home/<user></code>	zdalny katalog instalacji
<code>-u, --user</code>	<code>chapel</code>	użytkownik SSH
<code>-p, --port</code>	<code>22</code>	port SSH
<code>-V, --chapel-version</code>	<code>2.9.0</code>	wersja Chapel (nazwa katalogu drzewa)
<code>-m, --mpi-dir</code>	<code><dir>/mpi</code>	prefiks MPICH (kanał <code>mpi</code>)
<code>-o, --output</code>	<code>heat3d</code>	nazwa pliku wykonywalnego programu
<code>-s, --skip-compile</code>	wyłączony	pomiń kompilację, użyj istniejących plików wykonywalnych

Typowy przebieg pomiarowy składa się z trzech poleceń wykonywanych na węźle głównym. Najpierw budowa i dystrybucja, z kanałem `mpi` i wskazanym drzewem Chapel:

```
1 ./compile-and-distribute.sh -f hosts.txt -c mpi -d /home/chapel/
  workspace
```

Listing 3.5: Budowa i rozesłanie plików wykonywalnych na klaster.

Następnie uruchomienie programu na zadanej liczbie węzłów, z parametrami dziedziny i liczby kroków przekazanymi jako flagi `config`, oraz z żądaną liczbą wątków na lokal:

```
1 CHPL_RT_NUM_THREADS_PER_LOCALE=4 ./run-heat3d.sh --nx=1000 --
  numSteps=100
```

Listing 3.6: Uruchomienie przebiegu pomiarowego.

Na koniec, po serii przebiegów, scalenie rozproszonych zrzutów i opcjonalny render filmu:

```
1 ./aggregate-heat3d.sh --render=true
```

Listing 3.7: Agregacja rozproszonych fragmentów i wizualizacja.

3.2 Struktura programu i krok obliczeniowy

3.2.1 Dziedzina rozproszona z otoczką

Podstawą implementacji jest trójwymiarowa dziedzina rozproszona między lokale za pomocą rozkładu `StencilDist` [4], utrzymującego otoczkę (*fluff*) o grubości jednej komórki. Definicję dziedziny oraz jej wnętrza przedstawia listing 3.8.

```
1 const domain3D = stencilDist.createDomain({0..<nx,0..<ny,0..<nz},
2                                           fluff=(1,1,1));
3 const interior = domain3D.expand(-1);
```

Listing 3.8: Definicja dziedziny rozproszonej z jednokomórkową otoczką oraz jej wnętrza.

Wnętrze `interior` powstaje przez zmniejszenie dziedziny o jedną komórkę w każdym kierunku (`expand(-1)`); obejmuje ono wyłącznie te komórki, dla których siedmiopunktowy stencil ma komplet sąsiadów wewnątrz dziedziny globalnej. Komórki brzegowe, wyłączone z wnętrza, pełnią rolę stałego warunku brzegowego typu Dirichleta.

3.2.2 Pojedynczy krok obliczeniowy

Pojedynczy krok czasowy realizuje procedura `stepOnce`, przedstawiona w listingu 3.9. Dzieli ona krok na dwie fazy, wymiany halo i obliczenia stencila, mierzone osobnymi stoperami.


```

1 proc stepOnce(ref dst, ref src, ref fluffTimer, ref computeTimer) {
2   fluffTimer.start(); src.updateFluff(); fluffTimer.stop();
3   computeTimer.start();
4   forall (i,j,k) in interior do
5     dst[i,j,k] = src[i,j,k]
6                 + ax*(src[i-1,j,k]-2*src[i,j,k]+src[i+1,j,k])
7                 + ay*(src[i,j-1,k]-2*src[i,j,k]+src[i,j+1,k])
8                 + az*(src[i,j,k-1]-2*src[i,j,k]+src[i,j,k+1]);
9   computeTimer.stop();
10 }

```

Listing 3.9: Procedura pojedynczego kroku: wymiana halo, a następnie obliczenie stencila.

Metoda `updateFluff()` kopiuje komórki brzegowe każdego lokala do otoczek sąsiadów przez GASNet; jest to jedyna komunikacja kroku, obowiązkowa dla poprawności w konfiguracji wielolokalowej. Stanowi ona jednocześnie główne wąskie gardło obliczeń rozproszonych. Przebieg pojedynczego kroku wraz z fazą zapisu ilustruje rysunek 3.2.



Rysunek 3.2: Potok pojedynczego kroku czasowego programu. Faza komunikacyjna (`updateFluff`) poprzedza lokalne obliczenie stencila, po którym następuje opcjonalny zapis fragmentu na dysk lokalny. Każda faza mierzona jest osobnym stoperem.

3.2.3 Ewolucja implementacji i operator zamiany buforów

Pętla czasowa programu zarządza dwoma polami, u oraz un , stanowiącymi odpowiednio pole bieżące i poprzednie; po każdym kroku role te należy zamienić, by kolejny krok czytał z bufora przechowującego najnowszy stan. W niniejszej sekcji omówiono ewolucję tego mechanizmu oraz wbudowany operator Chapel służący do zamiany buforów, stosowany w głównym wariancie programu. Pozwala to uzasadnić wybór tego wariantu i odpowiedzieć na pytanie, czy sam sposób zamiany buforów wpływa na wydajność.

Najpierw zbudowano wersję jednowymiarową (`1d.chpl`) jako weryfikację pomysłu, a następnie dwuwymiarową (`2d.chpl`); obie stanowiły kolejne kroki rozwojowe prowadzące do przypadku trójwymiarowego. W obu tych wariantach po każdym kroku obliczeniowym wykonywano jawną zamianę buforów zapisem

```
1 un <=> u;
```

Listing 3.10: Zamiana buforów operatorem `<=>` stosowana w wariantach 1D i 2D oraz w wczesnej wersji 3D.

po każdej aktualizacji pole bieżące zamieniało się więc z polem poprzednim, tak by kolejny krok czytał z bufora przechowującego najnowszy stan.

Wczesna wersja trójwymiarowa, zanim wprowadzono opisany w podrozdziale 3.3 rozproszony zapis fragmentów, renderowała klatki bezpośrednio w trakcie symulacji za pomocą modułu graficznego `Render3D`, wywoływanego w każdym kroku zewnętrznym. Takie rozwiązanie umieszczało kosztowne operacje wejścia-wyjścia i graficzne na ścieżce krytycznej obliczeń, co utrudniało czysty pomiar czasu pojedynczego kroku i wiązało się z zależnościami nieobecnymi na węzłach bezczłogowych. W ramach refaktoru usunięto moduł renderujący ze ścieżki obliczeniowej: stan pola zapisywany jest odtąd w postaci binarnych fragmentów przez procedurę `dumpLocal` opisaną w podrozdziale 3.3, a renderowanie przeniesiono do jednolokalowego postprocesora `aggregate3d.chpl` uruchamianego poza pętlą czasową. Jednocześnie z tym refaktorem rozdzielono sposób zarządzania buforami na dwa warianty przeznaczone do wzajemnego porównania.

Wariant `3d.chpl`, stosowany we wszystkich pomiarach, zachowuje stałe role argumentów, zawsze wywołując `stepOnce(u, un, ...)`, a po każdym kroku wykonuje wspomnianą wyżej zamianę operatorem `<=>`; jego pętla główna przedstawiona jest w listingu 3.11. Dla porównania zaimplementowano również wariant ping-pong (`3d_pingpong.chpl`), w którym role bufora docelowego oraz źródłowego są naprzemiennie, co wyraża warunek `writeToU = (step % 2 == 1)`: w krokach nieparzystych wynik pisany jest do `u`, a w parzystych do `un`, dzięki czemu po parzystej liczbie kroków wynik znajduje się ponownie w pierwotnym buforze, bez jakiegokolwiek jawnej zamiany.

```
1 for step in 1..numSteps {
2   var fluffT, computeT, swapT, saveT: stopwatch;
3   stepOnce(u, un, fluffT, computeT); // stale: dst=u, src=un
4   swapT.start();
5   un <=> u;                          // zamiana buforow
6   swapT.stop();
7   if step % dumpEvery == 0 then
8     dumpLocal(un, frame);            // un zawsze trzyma
9                                     najnowszy stan
9 }
```

Listing 3.11: Pętla główna wariantu `3d.chpl`: stałe role buforów i jawna zamiana operatorem `<=>` po każdym kroku, mierzona osobnym stoperem.

Sercem głównego wariantu jest operator `<=>`, wbudowany operator zamiany tablic w Chapel. Dla rozkładu `StencilDist` nie powoduje on kopiowania elementów: implementacja operatora próbuje najpierw ścieżkę `doiOptimizedSwap`, która zamienia wewnętrzne wskaźniki danych obu tablic w czasie stałym, $O(1)$, bez ruchu danych i bez generowania komunikacji sieciowej. Ponieważ `StencilDist`, podobnie jak `BlockDist`, implementuje tę ścieżkę zoptymalizowaną, zamiana sprowadza się do przepięcia wskaźników lokalnych buforów na każdym lokalu. Jedynym dodatkowym kosztem jest fakt, że `doiOptimizedSwap` wykonuje się w postaci `coforall loc in Locales do on loc { ... }`, co wprowadza jedną barierę synchronizacyjną między lokalem po każdym kroku. Wariant ping-pong omija tę barierę całkowicie, bo nie wykonuje żadnej zamiany, lecz jedynie naprzemiennie odczytuje role argumentów.

Ponieważ zamiana `<=>` nie przenosi danych, jej koszt nie przekracza kosztu wspomnianej bariery, czyli ułamka czasu pojedynczego kroku. Czas kroku pozostaje zdominowany przez wymianę halo oraz zapis fragmentu na dysk, por. rysunek 3.2; operator zamiany jest wobec nich wielkością rzędu znikomego. Z tego powodu sposób zarządzania buforami nie ma znaczącego wpływu na wydajność. Wariant `3d.chpl` stosowany w pomiarach na klastrze Pionier jest ponadto wyposażony w osobny stoper `swapT` mierzący sam czas zamiany, co pozwala wyodrębnić ten składnik z całkowitego czasu kroku; wariant ping-pong (`3d_pingpong.chpl`) pozostawiono jako punkt odniesienia pomijający barierę zamiany.

3.2.4 Pomiar czasu i rejestrowanie

Program rozdziela pomiar czasu na wyraźnie zdefiniowane obszary. Stoper `initTimer` obejmuje fazę przygotowania (alokacja tablic, inicjalizacja gorącej warstwy oraz obliczenie kroku czasowego `dt` i współczynników), której wynik raportowany jest jako *Initialization time*. Stoper `computeTimer` obejmuje całą pętlę czasową i raportowany jest jako *Execution time*. Dla każdego kroku wypisywana jest linia `step <n> updateFluff=<s> s compute=<s> s save=<s> s`. Ponadto rejestrator `commLog` wypisuje jednorazowo linię `[comm] <bytes> B/step across <N> locale(s)` oraz przyrostowe liczby operacji `put/get/on/amo` na każdy krok, co pozwala powiązać obserwowany czas z faktyczną objętością komunikacji.

Efektywną liczbę wątków na lokal wypisuje sekwencyjna pętla `for` po lokalach, przez co linie są uporządkowane według identyfikatora lokala:

```
1 for loc in Locales do on loc do
2   writeln("[cfg] locale ", here.id, " maxTaskPar=", here.maxTaskPar
   );
```

Listing 3.12: Wypisanie efektywnej liczby wątków dla każdego lokala.

3.2.5 Parametry konfiguracyjne

Zachowanie programu sterowane jest zbiorem stałych konfiguracyjnych `config const`, które można nadpisać z linii poleceń bez rekompilacji. Ich domyślne wartości (dla wariantu `3d.chpl`) zestawiono w tabeli 3.2. Domyślny rozmiar sześcianu $20 \times 20 \times 20$ służy szybkiej weryfikacji; do eksperymentów wydajnościowych podnoszony jest do znacznie większych wartości. Parametr `alpha` to bezwymiarowy współczynnik dyfuzji wykorzystywany do obliczenia współczynników stencila, a `hotThickness` określa liczbę warstw wzdłuż osi y inicjalizowanych wartością 2,0 (gorąca warstwa startowa).

Tabela 3.2: Stałe konfiguracyjne programu i ich wartości domyślne (wariant `3d.chpl`).

Parametr	Wartość domyślna	Znaczenie
<code>nx, ny, nz</code>	20	wymiary siatki w trzech osiach
<code>numSteps</code>	100	liczba kroków czasowych
<code>alpha</code>	0,25	współczynnik dyfuzji
<code>hotThickness</code>	2	liczba gorących warstw wzdłuż osi y
<code>debug</code>	false	tryb diagnostyczny
<code>dumpDir</code>	frames	katalog zrzutów
<code>dumpEvery</code>	100	co ile kroków zapisywać klatkę
<code>compress</code>	true	kompresja zrzutów <code>gzip</code>
<code>trackMem</code>	false	śledzenie zużycia pamięci
<code>commLog</code>	false	rejestrowanie statystyk komunikacji

3.2.6 Rejestrowanie przebiegów

Sposób rejestrowania przebiegów zapewnia jednoczesny podgląd postępu, trwałe zapis do dalszej analizy i jednoznaczne wiązanie logu z konfiguracją, w której powstał. W tym celu wyjście uruchamianego programu przechwytywane jest poleceniem `tee` działającym po ustawieniu `set -o pipefail`, dzięki czemu kod wyjścia potoku odzwierciedla wynik programu, a nie polecenia `tee`, co pozwala wykryć awarię przebiegu (por. listing 3.3).

Nazwa pliku logu zawiera znacznik czasu w postaci `logs/<bin>-YYYYmmdd-HHMMSS.log`, przez co kolejne przebiegi tego samego pliku wykonywalnego nie nadpisują się nawzajem i pozostają rozróżnialne w czasie.

3.3 Buforowanie, zapis i agregacja danych

3.3.1 Zapis fragmentów na dysk lokalny

Zapis stanu pola do dalszej wizualizacji zaprojektowano tak, aby ciężkie operacje wejścia-wyjścia nie obciążały ścieżki krytycznej obliczeń. Procedura `dumpLocal`, pokazana w listingu 3.13, powoduje, że *każdy* lokal zapisuje wyłącznie własny podblok na lokalny system plików danego węzła; nie następuje żadne globalne zgromadzenie danych (*gather*) w jednym miejscu. Dzięki temu zapis jest w pełni rozproszony i skaluje się z liczbą węzłów.

```
1 proc dumpLocal(ref field, frameIdx: int) throws {
2   coforall loc in Locales do on loc {
3     const ld = field.localSubdomain();
4     const base = dumpDir + "/frame_" + frameIdx:string
5                 + "_loc_" + here.id:string + ".bin";
6     var block: [ld] real = field[ld];
7     // zapis nagłówka i surowego bloku (opcjonalnie przez gzip)
8   }
9 }
```

Listing 3.13: Rozproszony zapis: każdy lokal zapisuje własny podblok lokalnie.

Powstający plik nosi nazwę `frame_<idx>_loc_<localeId>.bin` (lub `.bin.gz` przy kompresji) w katalogu `dumpDir`. Nagłówek zawiera indeks klatki, identyfikator lokala, sześć globalnych granic i sześć granic lokalnych, po których następuje surowy blok liczb typu `real`. Kompresja (domyślnie `compress=true`) realizowana jest przez przekierowanie strumienia do uruchomionego procesu `gzip -c > file.gz`. Kompresja `gzip` jest bezstratna niezależnie od gładkości symulowanego pola i zmniejsza rozmiar danych około 190-krotnie, co czyni częste zrzucanie klatek przystępnym pod względem zajętości dysku. Parametr `dumpEvery` pełni rolę bramki (`step % dumpEvery == 0`), a licznik klatek zwiększa się przy każdym faktycznym zrzucie. Przed rozpoczęciem pętli każdy lokal wykonuje `rmTree` i `mkdir` na katalogu `dumpDir`, aby wyeliminować pozostałości po wcześniejszych przebiegach. W przebiegach z licznymi zrzutami klatek pojawiać się może błąd `ENOSPC` (numer 28), problem dyskowy, inny niż sieciowy `ECONGESTION`, i to rozróżnienie bywa istotne przy diagnostyce nieudanych przebiegów.

3.3.2 Agregacja rozproszonych fragmentów

Ponieważ dane zapisywane są w postaci rozproszonych podbloków, konieczny jest osobny etap ich scalenia. Realizuje go jednolokalowy post-procesor `aggregate3d`.

chp1. Dla każdej klatki alokuje on pełne, gęste pole, odnajduje wszystkie pliki `frame_<f>_loc_*.bin*` (rozpakowując warianty `.gz` poleceniem `gunzip -c`), a następnie odczytuje każdy podblok, którego nagłówek odzwierciedla format zapisany przez `dumpLocal`, i rozmieszcza go we właściwym miejscu pełnego pola. Rdzeń tej operacji pokazano w listingu 3.14.

```
1 const blockDom = {lo[0]..hi[0], lo[1]..hi[1], lo[2]..hi[2]};
2 var block: [blockDom] real;
3 r.readBinary(block);
4 full[blockDom] = block;
```

Listing 3.14: Rekonstrukcja pełnego pola: odczyt podbloku i rozmieszczenie go we właściwym miejscu.


Po zrekonstruowaniu pełnego pola dla danej klatki wywoływana jest procedura `renderFrame(full)`. Podział na rozproszony zapis i scentralizowaną agregację jest zamierzony: komunikacja globalna odbywa się raz, w trybie post-processingu, i nie obciąża czasu obliczeń.

3.3.3 Wizualizacja

Ostatnim etapem, uruchamianym wyłącznie z parametrem `--render=true`, jest renderowanie zdefiniowane w module `ImageUtils.chp1`. Kolejne klatki kodowane są do pliku wideo (z użyciem `mediaPipe`, poprzez klatki w formacie BMP) o nazwie `movieName` (domyślnie `heat.mp4`). Zastosowano mapę barw HSV odwzorowującą ciepło od niebieskiego do czerwonego: odcień wyznaczany jest jako $240(1 - t)$ stopni, gdzie $t = (T - T_{\min}) / (T_{\max} - T_{\min})$ jest temperaturą znormalizowaną do przedziału $[0, 1]$; wartość 240 odpowiada zimnemu błękitowi przy $t = 0$, a 0, gorącej czerwieni przy $t = 1$.

Trójwymiarowy renderer wokseli rysuje wyłącznie sześć zewnętrznych ścian sześciangu (wnętrze jest pomijane) w rzucie perspektywicznym z obrotem (parametry `rotX`, `rotY`, `camDist`, `cubeScale`). Zaimplementowano usuwanie ścian tylnych (*back-face culling*), bufor głębi (Z-bufor), dylatację punktów (`pointSize`) oraz dwanaście czarnych krawędzi sześciangu kreślonych algorytmem Bresenhama. Widoczne ściany próbkowane są o jedną komórkę do wnętrza, aby pominąć stałe woksele brzegowe (warunek Dirichleta).

Sześciang renderowany jest pod kątem, w widoku 3/4, od strony gorącej ściany $y = 0$. Ponieważ pięć ścian utrzymywanych jest w stałej temperaturze zimnej, a jedna w gorącej, render uwidacznia podtrzymywaną gorącą ścianę w kolorze czerwonym oraz gradient temperatury na widocznych ścianach bocznych, opadający ku zimnym krawędziom. Wynik dla dziedziny 64^3 przedstawiono na rysunku 3.3.



Rysunek 3.3: Render 3D pola temperatury dla dziedziny 64^3 , wykonany wbudowanym rendererem wokselowym programu z modułu `ImageUtils.chpl` i pokazany pod kątem od strony gorącej ściany. Widoczna jest podtrzymywana gorąca ściana $y = 0$ (czerwona, $T = 2$) oraz gradient na ścianach bocznych opadający ku zimnym ścianom ($T = 1$). Barwa odwzorowuje temperaturę w przedziale $[1, 2]$ zgodnie z mapą HSV od błękitu do czerwieni.

Opisana architektura, rozproszony zapis fragmentów bez globalnego gromadzenia, ich późniejsza agregacja poza ścieżką krytyczną oraz opcjonalna wizualizacja, oddziela operacje wejścia-wyjścia i komunikację zbiorową od właściwej pętli obliczeniowej. Jedynym elementem komunikacyjnym tej pętli pozostaje wymiana halo omówiona w podrozdziale 3.2. Pełny kod źródłowy programu, skrypty uruchomieniowe oraz narzędzia analizy stanowią załącznik elektroniczny do niniejszej pracy, co umożliwia odtworzenie opisanych eksperymentów.

Rozdział 4

Metodologia badań

4.1 Scenariusze i metryki

4.1.1 Scenariusze badawcze

Badania podzielono na dwie grupy: weryfikację poprawności oraz pomiary wydajności i skalowania. Weryfikacja poprawności obejmowała sprawdzenie, że wynik obliczeń jest niezależny od liczby lokacji, na które rozdzielono dziedzinę, pod warunkiem prawidłowej wymiany warstw brzegowych. Jako niezmiennik kontrolny wykorzystano sumę wartości pola w stanie końcowym, raportowaną przez program w wierszu `final field: min=... max=... sum=....`. Ponieważ pole przyjmuje wartości w przedziale $[1, 2]$, a jego średnia jest bliska jedności, suma jest w przybliżeniu równa liczbie komórek siatki.

Pomiary wydajności obejmowały cztery grupy scenariuszy, zestawione w tabeli 4.1:

- **skalowanie wątkowe w obrębie węzła:** jedna lokacja ($-n1\ 1$), zmienna liczba wątków 1/2/4/8/16; przeprowadzone dla kostki 1000^3 na węźle Pionierlab8-1 o 20 wątkach;
- **skalowanie wątkowe przy 9 lokacjach:** kostka 1000^3 , ustalona liczba lokacji, zmienna liczba wątków na lokację;
- **skalowanie po liczbie węzłów:** kostka 1000^3 , 16 wątków na lokację, liczba lokacji od 1 do 9;
- **skalowanie rozmiaru zadania:** 9 lokacji, 16 wątków na lokację, krawędź kostki od 125 do 1000 (a więc od 125^3 do 1000^3 komórek).

Skalowanie wątkowe w obrębie węzła i skalowanie po węzłach rozdzielono świadomie: to dwa różne mechanizmy równoległości, współdzielenie pamięci przez wątki

Tabela 4.1: Grupy scenariuszy pomiarowych. Liczbę wątków w pierwszej grupie oznaczono symbolem p , liczbę lokacji symbolem L , a krawędź kostki symbolem N .

Scenariusz	Zmienna	Ustalone	Środowisko
Wątki, 1000 ³	$p \in \{1,2,4,8,16\}$	$L=1, N=1000, 10$ kroków	węzeł Pionier-lab8-1 (20 wątków)
Wątki, 9 lokacji	$p \in \{1,2,4,8,16\}$	$L=9, N=1000, 100$ kroków	klaster (9 węzłów)
Węzły	$L \in \{1, \dots, 9\}$	$p=16, N=1000, 100$ kroków	klaster (9 węzłów)
Rozmiar kostki	$N \in \{125, \dots, 1000\}$	$p=16, L=9, 100$ kroków	klaster (9 węzłów)

jednej lokacji oraz rozproszenie danych między lokacjami połączone z komunikacją sieciową. Dopiero zestawienie obu perspektyw pozwala zidentyfikować czynnik ograniczający wydajność.

W scenariuszach wielowęzłowych liczbę wątków na lokację pozostawiono wartości domyślnej warstwy `qthreads`, która dla dwudziestowątkowych węzłów ustala 16 wątków efektywnych, rezerwując pozostałe rdzenie dla wątku komunikacyjnego GASNet; jedyną zmienną niezależną była odpowiednio liczba węzłów lub rozmiar dziedziny.

Wszystkie przebiegi wykorzystują ten sam zestaw parametrów numerycznych. Współczynnik dyfuzji przyjęto bezwymiarowo $\alpha = 0,25$, a gorącą warstwę startową o grubości `hotThickness=2` płaszczyzn inicjalizowano wzdłuż osi y przy ścianie $y = 0$. Krok czasowy dobierany jest automatycznie z warunku (2.7) ze współczynnikiem bezpieczeństwa $\Delta t = 0,98 \Delta t_{\max}$ (wzór (2.8)); dla największej badanej kostki $N = 1000$ daje to $\Delta t \approx 6,55 \cdot 10^{-7}$. Liczba kroków czasowych K zależy od grupy scenariusza: wynosi 10 przy skalowaniu wątkowym na pojedynczym węźle oraz 100 w eksperymentach wielowęzłowych (patrz tabela 4.1).

4.1.2 Metryki

Podstawową wielkością mierzoną jest *czas wykonania* T , rozumiany jako czas trwania całej pętli czasowej, mierzony zegarem `computeTimer` w lokalu głównym (locale 0). Ponieważ krok czasowy zawiera barierę synchronizacyjną wymiany halo, wszystkie lokale kończą krok w tym samym czasie, więc pomiar z lokalu głównego jest reprezentatywny dla całego przebiegu. Czas ten nie obejmuje inicjalizacji, mierzonej osobno zegarem `initTimer`.

Na podstawie czasu wykonania zdefiniowano standardowe miary skalowania silnego [17]: przyspieszenie $S(p) = T(1)/T(p)$ oraz wydajność równoległą $E(p) = S(p)/p$, zdefiniowane już wzorami (2.9) i (2.10), gdzie $T(1)$ jest czasem wykonania

konfiguracji odniesienia z jednym wątkiem albo jedną lokacją. Przy czym w roli p dla skalowania wątkowego przyjęto *efektywną* liczbę wątków, tj. wartość `maxTaskPar` po ewentualnym ograniczeniu przez warstwę wątkową, a nie liczbę żadaną. Dla oceny wykorzystania sprzętu niezależnie od rozmiaru zadania posłużono się *przepustowością* wyrażoną w miliardach aktualizacji komórek na sekundę,

$$\Pi = \frac{N^3 \cdot K}{T \cdot 10^9}, \quad (4.1)$$

gdzie $N^3 \cdot K$ jest łączną liczbą aktualizacji komórek (wielkość bezwymiarowa), T jest czasem wykonania w sekundach, a czynnik 10^9 jest prefiksem giga zamieniającym aktualizacje na giga-aktualizacje; w konsekwencji Π wyrażone jest w giga-aktualizacjach komórek na sekundę, co odpowiada konwencji metryki GUPS z systemu HPC Challenge [19]. Dla oszacowania roli komunikacji wprowadzono *udział komunikacji* w czasie pojedynczego kroku,

$$\phi = \frac{t_{\text{fluff}}}{t_{\text{fluff}} + t_{\text{compute}}}, \quad (4.2)$$

gdzie t_{fluff} i t_{compute} są uśrednionymi po krokach czasami wymiany halo oraz obliczeń. Wielkość ϕ przyjmuje wartości bliskie jedności, gdy dominuje komunikacja, oraz bliskie zeru, gdy dominują obliczenia. Uzupełniając rejestrowano objętość wymiany halo w bajtach na krok, obliczaną analitycznie przez procedurę `haloBytesPerStep` jako łączną liczbę komórek warstw brzegowych wszystkich lokacji pomnożoną przez rozmiar elementu.

4.2 Procedura i narzędzia pomiarowe

4.2.1 Procedura pomiarowa

Każdą konfigurację uruchamiano dziesięciokrotnie, a jako wartość reprezentatywną przyjmowano *medianę* czasu wykonania. Wybór mediany zamiast średniej arytmetycznej jest istotny: pojedyncze przebiegi bywają zaburzone przez chwilowe zdarzenia systemowe, takie jak rywalizacja o rdzenie, przejściowe ograniczenie taktowania procesora czy aktywność innych procesów, które zawyżają czas, lecz nie odzwierciedlają właściwości badanej konfiguracji. Mediana jest odporna na takie wartości odstające, podczas gdy średnia zostaje przez nie zawyżona. Przykładem jest jedna z serii jednowęzłowych, w której trzy z dziesięciu przebiegów były wolniejsze o około pół sekundy (około 5 % czasu pojedynczego przebiegu) wskutek przejściowego ograniczenia taktowania; skutkowało to podwyższonym odchyleniem standardowym przy praktycznie niezmienionej medianie.

Przebiegi danej serii wykonywano sekwencyjnie, po jednym naraz, aby uniknąć wzajemnej rywalizacji o pamięć i pasmo. Wszystkie pomiary wydajności prowadzono na środowisku Chapel 2.9 z warstwą komunikacyjną w wariantcie mpi-conduit. Liczbę wątków na lokację ustawiano zmienną środowiskową `CHPL_RT_NUM_THREADS_PER_LOCALE`.

Konfigurację każdego przebiegu zapisywano bezpośrednio w logu w postaci linii `[cfg]` opisanych w podrozdziale 3.1.6: skrypt podaje żadaną liczbę wątków i lokacji, a program efektywną liczbę wątków po ograniczeniu przez warstwą `qthreads`. Na węzłach Pionier o 20 wątkach sprzętowych liczba efektywna była równa żądanej dla wszystkich badanych konfiguracji ($p \leq 16$).

4.2.2 Narzędzia pomiarowe

Czasy mierzono wbudowanymi w język stoperami (`stopwatch`), opartymi na zegarze monotonicznym wysokiej rozdzielczości o praktycznej rozdzielczości pojedynczych mikrosekund, osobno dla inicjalizacji, całej pętli czasowej oraz, w każdym kroku, dla wymiany halo, obliczeń i zapisu. Objętość i liczbę operacji komunikacyjnych GET, PUT, zdalnych i atomowych rejestrowano za pomocą modułu diagnostyki komunikacji GASNet, włączanego przełącznikiem `commLog`; wypisywany raz wiersz `[comm]` podaje analityczną objętość wymiany halo na krok. Zużycie pamięci procesu kontrolowano narzędziem systemowym `/usr/bin/time -v`, odczytując maksymalny rezydentny zbiór stron (ang. *Resident Set Size*, RSS), co pozwoliło ustalić graniczne rozmiary kostek mieszczące się w pamięci danego węzła.

Przetwarzanie zebranych logów oraz rysowanie wykresów zrealizowano skryptami w języku Python z biblioteką `matplotlib`. Podstawową formą prezentacji jest wykres pudełkowy rozkładu czasu wykonania z naniesionymi punktami poszczególnych przebiegów, medianą oraz średnią; uzupełniają go wykresy metryk pochodnych: przyspieszenia, wydajności, przepustowości i udziału komunikacji. Taka forma pokazuje jednocześnie środek rozkładu i rozrzut, co jest istotne przy ocenie powtarzalności.

Do diagnozy zachowania sieci wykorzystano dedykowany skrypt sondujący, który równocześnie obciąża łącze strumieniem `iperf3` w trybie UDP o przepływności zbliżonej do granicy łącza oraz monitoruje straty pakietów z kilku niezależnych perspektyw: procentu utraconych pakietów ICMP, przyrostów liczników odrzuceń na lokalnym interfejsie sieciowym oraz, co najważniejsze, przyrostów liczników błędów bufora odbiorczego UDP po stronie odbiorcy (`InErrors`, `RcvbufErrors`). Rosnące błędy bufora odbiorczego pod obciążeniem są bezpośrednim dowodem przeciążenia typu *incast*, które w wariantcie AMUDP prowadzi do awarii typu `ECONGESTION` [18]. Narzędzie to pozwoliło odróżnić przyczyny sieciowe od obliczeniowych i dyskowych

oraz uzasadnić wybór wariantu transportu opartego na protokole TCP.

4.2.3 Przykład wyznaczenia metryk

Dla uporządkowania powyższych definicji poniżej przedstawiono sposób wyznaczenia metryk pochodnych na jednym scenariuszu. Rozważono skalowanie wątkowe kostki 1000^3 na węźle Pionier o 20 wątkach. Konfiguracja odniesienia z jednym wątkiem osiągnęła medianę czasu wykonania $T(1) = 9,812 s$, natomiast optymalna konfiguracja ośmiowątkowa $T(8) = 8,094 s$. Zgodnie z (2.9) przyspieszenie wynosi $S(8) = 9,812/8,094 \approx 1,212$, a wydajność równoległa według (2.10), $E(8) = 1,212/8 \approx 0,152$. Przepustowość dla tej konfiguracji, przy $K = 10$ krokach, obliczono z (4.1) jako $\Pi = 1000^3 \cdot 10 / (8,094 \cdot 10^9) \approx 1,24$ miliarda aktualizacji komórek na sekundę. Zabieg ten powtórzono dla każdej konfiguracji każdego scenariusza, dzięki czemu wszystkie wykresy i zestawienia w rozdziale 5 opierają się na jednolicie zdefiniowanych wielkościach.

4.2.4 Kontrola warunków i zagrożenia dla trafności

Wiarygodność wniosków zależy od kontroli czynników zakłócających. W toku badań zidentyfikowano i ograniczono kilka takich czynników.

Zmienność środowiska pochodzi ze współdzielenia maszyny z innymi procesami oraz dynamicznego zarządzania taktowaniem procesora, co wprowadza zmienność czasu wykonania. Ograniczono ją przez sekwencyjne uruchamianie przebiegów, dziesięciokrotne powtórzenia oraz stosowanie mediany. Tam, gdzie mimo to pojawiły się wartości odstające, czyli pojedyncze wolniejsze przebiegi wskutek przejściowego ograniczenia taktowania, fakt ten odnotowano jawnie i potraktowano jako artefakt pomiaru, a nie własność konfiguracji.

Nierówny podział dziedziny pojawia się, gdy liczba lokacji nie dzieli równo boku kostki 1000^3 ; powoduje to nierównomierne obciążenie i zaburza gładkość krzywej skalowania. Nie jest to błąd pomiaru, lecz rzeczywista własność dekompozycji; uwzględniono ją w interpretacji niemonotonicznego przebiegu skalowania po węzłach.

Trafność zewnętrzna wyników jest ograniczona: uzyskano je na konkretnym, niewielkim klastrze z siecią 1 Gb/s. Wartości bezwzględne nie przenoszą się wprost na inne środowiska, natomiast wnioski, ograniczenie przepustowością pamięci i komunikacją, korzystny wpływ większych zadań na wykorzystanie klastra, mają charakter ogólny i wynikają z właściwości samych obliczeń stencilowych [15, 16].

Rozdział 5

Wyniki i analiza

5.1 Poprawność i wydajność wariantów

Główny wariant programu zarządza buforami operatorem zamiany $\leq\Rightarrow$; rozważono też wariant naprzemiennego buforowania (ping-pong). Ponieważ oba nie różnią się znacząco wydajnością, dalsze wyniki dotyczą wariantu głównego z operatorem zamiany.

5.1.1 Weryfikacja poprawności numerycznej

Przed przystąpieniem do jakichkolwiek pomiarów wydajnościowych konieczne było ustanowienie wiarygodnego kryterium poprawności obliczeń. Bez takiego kryterium przyspieszenie z równoległości nie ma znaczenia, łatwo bowiem uzyskać krótszy czas wykonania kosztem cichego naruszenia poprawności wyniku. W przypadku badanego programu przyjęto niezmiennik oparty na własnościach pola temperatury oraz na jego całkowitej sumie.

Warunki początkowe i brzegowe zadania dobrano tak, aby rozwiązanie pozostawało przez cały czas symulacji ograniczone do przedziału $[1, 2]$. Program po zakończeniu obliczeń raportuje statystyki końcowego pola w postaci wpisu `final field: min=1.0 max=2.0 sum=<S>`. Utrzymanie dolnej granicy 1,0 oraz górnej granicy 2,0 jest bezpośrednią konsekwencją zasady maksimum dla równania przewodnictwa cieplnego: schemat jawny z odpowiednio dobranym krokiem czasowym nie może wygenerować wartości spoza zakresu wyznaczonego przez dane początkowe i brzegowe. Naruszenie któregoś z tych ograniczeń natychmiast sygnalizowałoby błąd implementacji schematu różnicowego lub niestabilność numeryczną.

Kluczową rolę w weryfikacji odgrywa jednak suma wszystkich elementów pola, w przybliżeniu równa liczbie komórek siatki. Jednocześnie suma S dobrze oddaje stan całej dziedziny i szybko reaguje na różnice między konfiguracjami: najmniejsze

rozejście się wyników widać jako rozbieżność sum.

Właśnie na tej podstawie zweryfikowano poprawność obliczeń wielowęzłowych. Przebieg uruchomiony na pojedynczym locale (`-nl 1`) daje pewną wartość sumy odniesienia. Ten sam problem rozdzielony na N locale daje identyczną sumę *pod warunkiem*, że po każdym kroku czasowym wykonywana jest wymiana warstw brzegowych (halo) za pomocą operacji `updateFluff`. Pominięcie tej wymiany skraca czas wykonania, lecz suma S zaczyna się rozchodzić względem wartości odniesienia; wynik staje się *cicho błędny*. Wymiana warstw brzegowych jest więc niezbędna do poprawności i nie da się jej pominąć dla zysku wydajności. Suma jest przy tym miarą odporną na błędy systematyczne, do jakich należy pominięcie wymiany halo, które rozchodzi pole w jednym kierunku, a nie na błędy kompensujące się; ponadto zasada maksimum ogranicza każdą komórkę do przedziału $[1, 2]$, więc punktowe naruszenie tej granicy zostałoby wychwycone niezależnie od sumy. Ta obowiązkowa komunikacja, jak pokazano w podrozdziale 5.2, jest głównym wąskim gardłem systemu.

5.1.2 Skalowanie wątkowe na pojedynczym węźle

W tej części przeanalizowano wydajność jednowęzłową. Celem tej serii eksperymentów było zbadanie, jak czas wykonania programu zależy od liczby wątków obliczeniowych przy ustalonym rozmiarze zadania, a zatem ile faktycznie zyskuje się na zrównolegleniu wewnątrzwęzłowym. Pomiary wykonano dla dziedziny 1000^3 na węźle klastra Pionier.

Tabela 5.1 przedstawia wyniki tego eksperymentu; faktyczna liczba zadań qth-reads jest tu równa liczbie żądanej.

Tabela 5.1: Skalowanie wątkowe na pojedynczym węźle, dziedzina 1000^3 , `-nl 1`, 10 kroków $\times$ 10 powtórzeń, Chapel 2.9, kanał MPI, węzeł Pionier.


Żądane wątki	maxTaskPar	Mediana [s]	Średnia [s]	Min. [s]	Maks. [s]	Odch. std. [s]	S	E
1	1	9,812	9,814	9,803	9,829	0,008	1,000	1,000
2	2	9,948	10,104	9,941	10,470	0,240	0,986	0,493
4	4	8,362	8,362	8,356	8,365	0,003	1,173	0,293
8	8	8,094	8,095	8,087	8,101	0,004	1,212	0,152
16	16	8,739	8,741	8,731	8,763	0,008	1,123	0,070

Obraz jest tu jakościowo odmienny i znacznie korzystniejszy. Przejście z jednego do dwóch wątków nie przynosi niemal zysku: mediana rośnie z 9,812s do 9,948s, a trzy z dziesięciu przebiegów dwuwątkowych były wyraźnie wolniejsze, około 10,47s, wskutek przejściowego ograniczenia taktowania. Dopiero cztery wątki dają wyraźny

skok wydajności, mediana spada do 8,362 s (przyspieszenie 1,173), a optimum osiągnięte jest przy ośmiu wątkach (8,094 s, przyspieszenie 1,212). Dalsze zwiększanie liczby wątków ponownie szkodzi: przy szesnastu czas rośnie do 8,739 s. Maksymalne uzyskane przyspieszenie wynosi zatem tylko około $1,21\times$, mimo dostępności dwudziestu wątków.

Wydajność E spada przy tym bardzo ostro: z 1,000 przez 0,493 i 0,293 aż do 0,070 przy szesnastu wątkach. Tak gwałtowny spadek to typowy objaw problemu *ograniczonego pasmem pamięci* [16]. Schemat różnicowy jest operacją o niskiej intensywności arytmetycznej, więc jego przepustowość limituje pasmo pamięci głównej, a nie liczba dostępnych rdzeni; po nasyceniu tego pasma dodatkowe wątki rywalizują o tę samą magistralę, co prowadzi do degradacji wydajności.

Zwiększanie liczby wątków ponad pewien próg nie pomaga tu, a wręcz szkodzi: po nasyceniu magistrali pamięci dodatkowe wątki nie znajdują użytecznej pracy. Rysunek 5.1 ilustruje te zależności: lewy panel przedstawia rozkład czasów wykonania w postaci wykresu pudełkowego, a prawy zestawia zmierzone przyspieszenie z przyspieszeniem idealnym oraz z krzywą wydajności, uwidaczniając odejście od skalowania liniowego już przy dwóch wątkach.



Rysunek 5.1: Skalowanie wątkowe dla dziedziny 1000³ na węźle Pionier. Lewy panel: rozkład czasu wykonania w postaci wykresu pudełkowego w funkcji liczby wątków. Prawy panel: zmierzone przyspieszenie na tle przyspieszenia idealnego oraz wydajność E .

W części jednowęzłowej równoległość wątkowa przynosi w najlepszym razie skromny, około dwudziestoprocentowy zysk, a wydajność szybko załamuje się wraz ze wzrostem liczby wątków. Bezpośrednią przyczyną jest ograniczenie pasmem pamięci; sytuacja ta pogłębia się dopiero przy skalowaniu na wiele węzłów.

5.2 Skalowanie i ograniczenia komunikacji

W tej części przeanalizowano zachowanie programu przy rozdzieleniu obliczeń na wiele węzłów klastra połączonych siecią Ethernet 1 Gb/s. Eksperymenty w tej sekcji przeprowadzono na klastrze dla dziedziny 1000^3 i 100 kroków czasowych. Wykazano, że badany system jest *ograniczony komunikacją*: to przepustowość sieci, a nie moc obliczeniowa węzłów, wyznacza pułap osiąganey wydajności.

5.2.1 Skalowanie liczbą węzłów

Tabela 5.2 przedstawia czas wykonania w funkcji liczby węzłów, od jednego do dwięciu, dla dziedziny 1000^3 . Oprócz statystyk czasu podano przyspieszenie, wydajność oraz objętość danych wymienianych w ramach warstw brzegowych na jeden krok czasowy w kolumnie „bajty/krok”.


Tabela 5.2: Skalowanie liczbą węzłów, dziedzina 1000^3 , 100 kroków.

Węzły	Mediana [s]	Średnia [s]	Min. [s]	Odch. std. [s]	S	E	Bajty/krok
1	87,344	87,307	87,104	0,092	1,000	1,000	0
2	51,943	51,957	51,858	0,107	1,682	0,841	16000000
3	52,978	53,413	52,862	1,316	1,649	0,550	32000000
4	36,670	36,889	36,203	0,894	2,382	0,595	32032000
5	41,476	41,482	41,347	0,093	2,106	0,421	64000000
6	32,240	32,243	32,076	0,115	2,709	0,452	48064000
7	37,114	37,112	36,909	0,156	2,353	0,336	96000000
8	42,941	42,909	42,419	0,198	2,034	0,254	48096064
9	36,832	36,817	36,469	0,157	2,371	0,263	64128000


Skalowanie węzłowe okazuje się wyraźnie *niemonotoniczne*. Zamiast oczekiwanego, systematycznego spadku czasu wraz ze wzrostem liczby węzłów, obserwuje się silny „ząbek” pomiędzy parzystymi a nieparzystymi liczbami węzłów. Najlepszy wynik uzyskano dla sześciu węzłów (mediana 32,240 s, przyspieszenie 2,709), podczas gdy sąsiednie konfiguracje pięcio- i siedmiowęzłowa wypadają zauważalnie gorzej (41,476 s oraz 37,114 s). Źródłem tego zjawiska jest nierównomierny podział dziedziny 1000^3 : gdy liczba węzłów nie dzieli gładko boku kostki, powstaje niezrównoważenie obciążenia, w którym niektóre węzły otrzymują większe poddziedziny i stają się elementem spowalniającym całość, co dodatkowo splata się ze wzrostem objętości komunikacji między węzłami.

Niezależnie od tych oscylacji, obraz ogólny jest jednoznaczny: przyspieszenie *plaszczy się* na poziomie około $2,4\times$ i nie zbliża się do skalowania liniowego, mimo

dziesięciokrotnego zwiększenia liczby węzłów [17]. Wydajność spada z 1,000 do za-
ledwie 0,263 przy dziewięciu węzłach. Kluczem do wyjaśnienia jest ostatnia kolumna
tabeli: objętość wymienianych warstw brzegowych rośnie w przybliżeniu liniowo wraz
z liczbą węzłów, od 0 bajtów dla pojedynczego węzła, w którym nie ma komunika-
cji międzywęzłowej, do ponad 64000000 bajtów na krok przy dziewięciu węzłach.
Każdy dodany węzeł wnosi pewną moc obliczeniową, lecz zarazem powiększa całko-
wity ruch sieciowy, a przy powolnym łączu ten drugi efekt szybko pochłania korzyść
z pierwszego. System jest zatem ograniczony komunikacją.



Rysunek 5.2: Skalowanie liczbą węzłów dla dziedziny 1000³. Lewy panel: rozkład czasu wykonania w funkcji liczby węzłów. Prawy panel: przyspieszenie na tle przyspieszenia idealnego oraz wydajność E .



Rysunek 5.3: Objętość warstw brzegowych wymienianych na krok w megabajtach oraz mediana czasu wykonania w funkcji liczby węzłów.

Zależności te zilustrowano na rysunek 5.2 oraz rysunek 5.3. Pierwszy z nich uwi-
adacznie zarówno oscylacyjny charakter czasu wykonania, jak i znaczne odejście krzy-
wej przyspieszenia od ideału liniowego. Drugi zestawia rosnącą objętość komunikacji
z czasem wykonania, czyniąc bezpośredni widoczny związek między nasilającym się
ruchem sieciowym a stagnacją wydajności.

5.2.2 Skalowanie wątkowe przy dziewięciu węzłach

Aby rozstrzygnąć, czy wąskim gardłem w konfiguracji wielowęzłowej jest komunikacja, czy może niedostateczne wykorzystanie rdzeni w obrębie węzła, powtórzono skalowanie wątkowe przy ustalonej liczbie dziewięciu węzłów. Wyniki zawiera tabela 5.3.

Tabela 5.3: Skalowanie wątkowe przy dziewięciu węzłach, dziedzina 1000^3 , 100 kroków.


Konfiguracja	Mediana [s]	Średnia [s]	Min. [s]	Odch. std. [s]	S	Obl./krok [s]
1 wątek	34,003	34,245	33,805	0,740	1,000	0,1422
2 wątki	35,217	35,252	33,715	1,184	0,966	0,1481
4 wątki	32,563	32,850	32,090	1,086	1,044	0,1600
8 wątków	34,694	34,616	34,215	0,245	0,980	0,1775
16 wątków	36,623	36,633	36,208	0,195	0,928	0,1982

Odpowiedź jest jednoznaczna. Czas wykonania pozostaje niemal płaski w zakresie od około 32 do 37 sekund niezależnie od liczby wątków, z płytkim minimum przy czterech wątkach (32,563 s). Przyspieszenie oscyluje wokół jedności i nigdy nie przekracza 1,044. Najbardziej wymowna jest jednak kolumna średniego czasu obliczeń na krok: rośnie ona *monotonicznie* wraz z liczbą wątków, od 0,1422 s przy jednym wątku do 0,1982 s przy szesnastu. Gdyby problem był ograniczony mocą obliczeniową, dodawanie wątków skracałoby czas obliczeń na krok; obserwuje się jednak zjawisko przeciwne: czas ten rośnie. Nie jest to skutek nadmiernej liczby wątków względem rdzeni, bo te pozostają wolne ($p \leq 16 \leq 20$), lecz rywalizacji o zasoby współdzielone: dodatkowe wątki nie znajdują użytecznej pracy, lecz konkurują o pasmo pamięci oraz z wątkiem odpytującym warstwę komunikacyjną GASNet [7]. Zwiększanie liczby wątków nie pomaga, ponieważ problem jest ograniczony komunikacją, a nie obliczeniami. Rysunek 5.4 przedstawia te zależności graficznie.

5.2.3 Skalowanie rozmiaru zadania

Ostatni zestaw eksperymentów bada wpływ rozmiaru dziedziny na wydajność przy ustalonej liczbie dziewięciu węzłów. Tabela 5.4 zestawia czasy wykonania, przepustowość wyrażoną w miliardach komórek na sekundę (mld komórek/s) oraz udział komunikacji `comm_frac` (4.2).

Wynik ten najlepiej potwierdza, że ograniczenie ma charakter komunikacyjny. Przepustowość rośnie systematycznie wraz z rozmiarem dziedziny, od zaledwie 0,117 mld komórek/s dla najmniejszej kostki 125^3 do 2,722 mld komórek/s dla największej kostki 1000^3 . Jednocześnie udział komunikacji `comm_frac` maleje monotonicznie



Rysunek 5.4: Skalowanie wątkowe przy dziewięciu węzłach, dziedzina 1000³. Lewy panel: rozkład czasu wykonania. Prawy panel: średni czas obliczeń na krok w funkcji liczby wątków, rosnący wskutek rywalizacji o zasoby współdzielone.

Tabela 5.4: Skalowanie rozmiaru dziedziny przy dziewięciu węzłach, 100 kroków.


Rozmiar	Mediana [s]	Średnia [s]	Przepustowość [mld komórek/s]	comm_frac
125 ³	1,668	1,670	0,117	0,963
250 ³	2,640	2,652	0,592	0,947
500 ³	7,625	7,673	1,639	0,729
1000 ³	36,741	36,802	2,722	0,454

z 0,963 do 0,454. Innymi słowy, dla małych dziedzin blisko 96 % czasu pochłania komunikacja, a faktyczne obliczenia stanowią margines; wraz ze wzrostem dziedziny proporcje te wyrównują się i przy 1000^3 komunikacja oraz obliczenia zajmują już zbliżony czas. Nawet przy największej zbadanej kostce komunikacja wciąż odpowiada za blisko połowę czasu kroku; trend jest wprawdzie korzystny, lecz w osiągalnym zakresie rozmiarów zadanie nie przestaje być istotnie obciążone komunikacją.

Mechanizm tego zjawiska jest geometryczny: objętość dziedziny rośnie jak N^3 , a powierzchnia warstw brzegowych jak N^2 , więc wraz ze wzrostem N poprawia się stosunek pracy obliczeniowej do komunikacji. Duże kostki znacznie lepiej wykorzystują klastery niż małe, zdominowane przez narzut komunikacyjny.

Rozmiar wymiany halo zależy od geometrycznego układu dekompozycji. Dla zilustrowania rozważmy dwuwymiarową dziedzinę 100×100 podzieloną na cztery lokale. Przy podziale plastrami wzdłuż jednej osi każdy blok ma wymiary 25×100 , dwa skrajne lokale wysyłają po 100 komórek brzegowych, a dwa wewnętrzne po 200, co daje łącznie 600 komórek wymienianych na krok. Przy podziale na bloki kwadratowe 50×50 każdy z czterech lokali wysyła do dwóch sąsiadów brzeg poziomy i pionowy po 50 komórek, co daje $4 \cdot (50 + 50) = 400$ komórek. W obu przypadkach objętość wymiany jest rzędu pola powierzchni granicy, a nie objętości, co w trzech wymiarach przekłada się na omówioną zależność N^2 .

Największą zbadaną dziedziną jest 1000^3 . Omówione zależności ilustruje rysunek 5.5.



Rysunek 5.5: Skalowanie rozmiaru dziedziny przy dziewięciu węzłach. Lewy panel: rozkład czasu wykonania dla kolejnych rozmiarów. Prawy panel: przepustowość oraz udział komunikacji `comm_frac` w funkcji rozmiaru kostki.

5.2.4 Synteza: system ograniczony komunikacją

Wyniki z tego rozdziału wskazują wspólnie, że system jest ograniczony komunikacją i przepustowością pamięci, a nie mocą obliczeniową. Przyspieszenie węzłowe płasz-

czy się na poziomie około $2,4\times$ (tabela 5.2), daleko od skalowania liniowego, mimo dziewięciokrotnego zwiększenia liczby węzłów. Zwiększanie liczby wątków na węzeł nie przynosi poprawy, a w konfiguracji wielowęzłowej średni czas obliczeń na krok wręcz rośnie z liczbą wątków (tabela 5.3), co wskazuje na nasycenie zasobów współdzielonych, a nie na niedobór mocy obliczeniowej. Udział komunikacji dominuje przy małych dziedzinach i maleje dopiero dla dużych kostek (tabela 5.4), zgodnie z geometryczną relacją między objętością N^3 a powierzchnią N^2 . Na każdym węźle jeden wątek warstwy komunikacyjnej GASNet obciąża rdzeń w niemal stu procentach, prowadząc aktywne odpytywanie (busy-polling) w oczekiwaniu na postęp komunikacji, co potwierdzono analizą stosów wywołań w debuggerze. To nie jest obciążenie obliczeniowe, lecz widoczny i mierzalny skutek ograniczenia komunikacją.

Fizycznym ograniczeniem jest łącze Ethernet o przepustowości 1 Gb/s, które dla dziedziny rzędu 1000^3 ulega nasyceniu. Objętość warstw brzegowych na krok rośnie zarówno z liczbą węzłów, jak i z kwadratem boku dziedziny, wobec czego to sieć, a nie procesory, wyznacza pułap wydajności.

Osobnego omówienia wymaga dobór kanału komunikacyjnego GASNet, który okazał się decydujący dla tego, czy obliczenia w ogóle kończą się poprawnie [6]. W pomiarach kanał `udp` przerywał działanie błędem `ECONGESTION` pod obciążeniem typu incast, natomiast kanał `mpi` kończył obliczenia poprawnie, choć wolniej. Z tego powodu nowsza seria pomiarów wykorzystuje kanał MPI: odporność na zawodną sieć jest tu ważniejsza od szybkości.

Skoro system jest ograniczony komunikacją, dalszej poprawy wydajności nie należy szukać ani w zwiększaniu liczby wątków, ani w dokładaniu kolejnych węzłów, lecz przede wszystkim w przyspieszeniu warstwy komunikacyjnej, czy to przez zastosowanie szybszego łącza sieciowego, czy przez wybór wydajniejszego kanału komunikacyjnego GASNet. Dopóki halo wymieniane jest przez łącze 1 Gb/s, klastr wciąż czeka na dane z sieci, a część rdzeni pozostaje niewykorzystana.

5.2.5 Zestawienie zbiorcze i powtarzalność

Dla wygody czytelnika zebrano najważniejsze wnioski ilościowe z poszczególnych grup eksperymentów w jednym miejscu. Tabela 5.5 podaje dla każdej serii kluczową miarę oraz jej najistotniejszy wynik.

Z zestawienia widać, że niezależnie od osi skalowania, liczby wątków, liczby węzłów czy rozmiaru zadania, wyniki trafiają na to samo ograniczenie: pasmo pamięci i komunikację. Jediną osią, wzdłuż której obserwuje się wyraźną poprawę efektywności wykorzystania klastra, jest rozmiar zadania: powiększanie kostki przesuwają proporcje na korzyść obliczeń, zgodnie z omówioną wcześniej relacją N^3 do N^2 .

Odrębnego komentarza wymaga powtarzalność pomiarów, stanowiąca podstawę

Tabela 5.5: Zestawienie zbiorcze najważniejszych wyników eksperymentalnych rozdziału.

Grupa eksperymentów	Kluczowa miara	Wynik
Wątki 1000 ³ (tabela 5.1)	optimum / maks. przyspieszenie	8 wątków; 1,21×
Węzły 1000 ³ (tabela 5.2)	optimum / plateau przyspieszenia	6 węzłów; ok. 2,4×
Wątki, 9 węzłów (tabela 5.3)	przyspieszenie (płaskie)	$\leq 1,044$
Rozmiar kostki (tabela 5.4)	przepustowość	0,117–2,722 mld komórek/s
Rozmiar kostki (tabela 5.4)	udział komunikacji <code>comm_frac</code>	0,963→0,454

zaufania do prezentowanych median. Zdecydowana większość serii charakteryzuje się bardzo niskim rozrzutem wyników. Dla serii 1000³ na węźle Pionier (tabela 5.1) odchylenie standardowe czasu wykonania nie przekracza 0,07 s, a dla większości konfiguracji jest rzędu zaledwie kilku tysięcznych sekundy. Tak niski rozrzut oznacza, że pojedynczy przebieg jest w tych przypadkach niemal równie miarodajny co mediana z dziesięciu powtórzeń, a różnice między konfiguracjami to rzędy dziesiątych sekundy lub więcej, więc nie da się ich wytłumaczyć samym szumem pomiarowym.

Osobną kwestią jest praktyczna granica rozmiaru zadania. Dziedzin istotnie większych niż 1000³ nie udało się ukończyć: przekraczają one możliwości pamięciowe i czasowe klastra, wobec czego nie figurują w żadnej tabeli i wyznaczają jedynie górny kres rozmiaru osiągalnego na badanej infrastrukturze. Świadomość tego ograniczenia nie podważa głównych wniosków rozdziału, które opierają się na seriach o niskim rozrzucie i dziesięciokrotnej powtarzalności, lecz trzeba o niej pamiętać, oceniając, do jakich rozmiarów zadania sięgają wnioski tej pracy.

Rozdział 6

Podsumowanie i wnioski

6.1 Wnioski

Celem pracy było zaprojektowanie, zaimplementowanie i wdrożenie na klastrze rozproszonego programu symulacyjnego rozwiązującego trójwymiarowe równanie przewodnictwa ciepła w języku Chapel oraz przeprowadzenie systematycznej analizy jego poprawności i skalowalności. Zrealizowano wszystkie założone cele, a wyniki potwierdzają tezę pracy: dla rozważanej klasy obliczeń stencilowych o czynniku ograniczającym wydajność decyduje nie moc obliczeniowa, lecz przepustowość pamięci na poziomie węzła oraz koszt komunikacji między węzłami [15].

W zakresie poprawności wykazano, że rozwiązanie różnicowe daje wynik niezależny od liczby lokacji, na które rozdzielono dziedzinę, pod warunkiem prawidłowej wymiany warstw brzegowych; niezmiennik sumy pola w stanie końcowym okazał się prostym, lecz skutecznym kryterium kontrolnym. Pominięcie wymiany halo znacząco skraca czas wykonania, lecz prowadzi do wyniku *cicho błędnego*, co pokazuje, że w programowaniu rozproszonym krótki czas wykonania nie oznacza jeszcze poprawnego wyniku.

Zrównoleglenie wątkowe w obrębie węzła nasycza się bardzo szybko: dla kostki 1000^3 optimum przypada na osiem wątków, a maksymalne przyspieszenie nie przekracza około $1,21\times$ mimo szesnastu dostępnych wątków, co jest sygnaturą ograniczenia przepustowością pamięci. Skalowanie po węzłach zatrzymuje się na poziomie około $2,4\times$ i pozostaje daleko od zależności liniowej, a jego przebieg jest niemonotoniczny, z najlepszym czasem przy sześciu węzłach, wskutek nierównego podziału kostki 1000^3 dla „niewygodnych” dzielników oraz rosnącej objętości wymiany halo; przy łączu 1 Gb/s czyni to obliczenia ograniczonymi komunikacją. Poprawę przynosi dopiero powiększanie zadania: wraz ze wzrostem krawędzi kostki przepustowość rośnie z 0,117 do 2,722 mld komórek na sekundę, a udział komunikacji maleje z 0,96 do 0,45, ponieważ objętość rośnie z sześcianem krawędzi, a powierzchnia wymiany

halo jedynie z jej kwadratem.

Praktyczne znaczenie miał dobór kanału komunikacyjnego GASNet. Wariant AMUDP, choć prosty, ulega awarii typu *ECONGESTION* pod obciążeniem typu *in-cast* i przy stratach pakietów, bo nie zapewnia kontroli przepływu [18]; *mpi-conduit* oparty na bibliotece MPICH i protokole TCP przetrwa te warunki dzięki kontroli przepływu i retransmisji, kosztem nieco niższej wydajności. Wyższa warstwa języka również miała znaczenie: globalny widok tablic, gotowy rozkład *StencilDist* z automatyczną wymianą otoczek oraz związane iteratory równoległe pozwoliły zapisać poprawny kod rozproszony znacznie prościej niż przy jawnym użyciu MPI [1, 2]. Abstrakcja ta nie zniosła jednak fundamentalnego ograniczenia komunikacyjnego: koszt wymiany halo pozostaje widoczny w wynikach i wyznacza granice skalowania. Model programowania nie zmienia właściwości sieci, co w tym przypadku oznacza, że produktywność i wydajność się uzupełniają, a nie zastępują.

6.2 Ograniczenia

Uzyskane wyniki należy interpretować z uwzględnieniem kilku ograniczeń.

Środowiskiem docelowym był niewielki, jednorodny klaster połączony siecią Ethernet o przepustowości 1 Gb/s, która jest wąskim gardłem i w znacznej mierze determinuje granice skalowania po węzłach. Na infrastrukturze z szybszą siecią o małych opóźnieniach, na przykład InfiniBand, można by oczekiwać lepszego skalowania oraz przesunięcia punktu, w którym program przestaje być ograniczony komunikacją, choć weryfikacja tej hipotezy wymagałaby odpowiedniego sprzętu. Praktyczną granicą jest też maksymalny rozmiar zadania: dziedzin istotnie większych niż 1000^3 nie udało się zmieścić w pamięci i czasie klastra.

Zakres pracy świadomie zawężono do jawnej metody różnic skończonych na siatce regularnej z arytmetyką podwójnej precyzji. Metody niejawne, które są bezwarunkowo stabilne, lecz wymagają rozwiązywania układów równań, siatki niestrukturalne, techniki nakładania komunikacji na obliczenia oraz akceleracja na procesorach graficznych pozostają poza zakresem, a każde z nich mogłoby zmienić charakterystykę obliczeniową problemu. Wreszcie badania dotyczyły wyłącznie skalowania silnego, przy ustalonym rozmiarze zadania i rosnącej liczbie jednostek równoległości; skalowanie słabe, gdzie rozmiar zadania rośnie proporcjonalnie do liczby lokacji, dałoby obraz uzupełniający.

6.2.1 Kierunki dalszych prac

Te ograniczenia wyznaczają naturalne kierunki dalszych prac.

Najbardziej obiecującym z nich jest nakładanie komunikacji na obliczenia: wymianę warstw brzegowych można rozpocząć asynchronicznie i w tym czasie liczyć wnętrza poddziedziny, które nie zależą od danych sąsiadów, ujawniając komunikację dopiero przy aktualizacji komórek przylegających do granicy. W języku Chapel wyraża się to naturalnie, za pomocą zadań asynchronicznych i jawnego rozdzielania wnętrza od brzegu poddziedziny.

Powtórzenie pomiarów na sieci o niskim opóźnieniu i wysokiej przepustowości, na przykład InfiniBand, wraz z kanałem komunikacyjnym GASNet dobranym do takiej sieci pozwoliłoby ustalić, w jakim stopniu obserwowane granice skalowania wynikają z samego algorytmu, a w jakim z ograniczeń konkretnego łącza 1 Gb/s. Uzupełniającą warto rozważyć skalowanie słabe, gdzie rozmiar zadania rośnie proporcjonalnie do liczby lokacji, co pozwoliłoby oddzielić koszty stałe od kosztów rosnących wraz z rozmiarem problemu.

Innym naturalnym rozszerzeniem są warianty numeryczne i sprzętowe: schematy niejawne, które są bezwarunkowo stabilne, lecz wymagają rozwiązywania układów równań i globalnej komunikacji innego typu, siatki niestrukturalne oraz akceleracja jądra obliczeniowego na procesorach graficznych, którą Chapel wspiera odpowiednimi lokacjami i atrybutami pętli równoległych. Każde z nich zmieniałoby charakterystykę obliczeniową problemu i pozwoliłoby sprawdzić, na ile wnioski tej pracy zachowują ważność poza klasą jawnych schematów stencilowych.

Z kolei inżynierskim uzupełnieniem byłoby pełne zautomatyzowanie potoku pomiarowego, od budowy i dystrybucji po zbieranie logów i generowanie wykresów, tak aby cały cykl badawczy był odtwarzalny jednym poleceniem. Wprowadzone w tej pracy elementy, czyli samoopisujące się logi oraz skrypty dystrybucji i analizy, mogą być bazą takiego potoku.

Bibliografia

- [1] B. L. Chamberlain, D. Callahan, H. P. Zima, *Parallel Programmability and the Chapel Language*, International Journal of High Performance Computing Applications, 21(3), 2007, s. 291–312.
- [2] B. L. Chamberlain, *Chapel*, w: P. Balaji (red.), *Programming Models for Parallel Computing*, MIT Press, 2015, s. 129–159.
- [3] The Chapel Team, *Chapel Language Specification and User Documentation*, wersja 2.9, Chapel a Series of LF Projects, LLC, 2026. <https://chapel-lang.org>.
- [4] The Chapel Team, *The Stencil Distribution (**StencilDist**): Standard Module Documentation*, 2026. <https://chapel-lang.org/docs/modules/dists/StencilDist.html>.
- [5] K. B. Wheeler, R. C. Murphy, D. Thain, *Qthreads: An API for Programming with Millions of Lightweight Threads*, IEEE International Symposium on Parallel and Distributed Processing (IPDPS), 2008.
- [6] D. Bonachea, P. H. Hargrove, *GASNet-EX: A High-Performance, Portable Communication Library for Exascale*, Languages and Compilers for Parallel Computing (LCPC 2018), LNCS 11882, Springer, 2019.
- [7] D. Bonachea, *GASNet Specification*, Technical Report UCB/CSD-02-1207, University of California, Berkeley, 2002 (rewidowana do wersji 1.8).
- [8] G. Almasi, *PGAS (Partitioned Global Address Space) Languages*, w: *Encyclopedia of Parallel Computing*, Springer, 2011, s. 1539–1545.
- [9] UPC Consortium, *UPC Language Specifications, v1.3*, Lawrence Berkeley National Laboratory, LBNL-6623E, 2013.
- [10] W. Gropp, *MPICH2: A New Start for MPI Implementations*, Recent Advances in PVM and MPI, LNCS 2474, Springer, 2002.

- [11] Message Passing Interface Forum, *MPI: A Message-Passing Interface Standard, Version 4.1*, 2023.
- [12] R. J. LeVeque, *Finite Difference Methods for Ordinary and Partial Differential Equations: Steady-State and Time-Dependent Problems*, SIAM, Philadelphia, 2007.
- [13] J. C. Strikwerda, *Finite Difference Schemes and Partial Differential Equations*, wyd. 2, SIAM, Philadelphia, 2004.
- [14] K. W. Morton, D. F. Mayers, *Numerical Solution of Partial Differential Equations*, wyd. 2, Cambridge University Press, 2005.
- [15] S. Williams, A. Waterman, D. Patterson, *Roofline: An Insightful Visual Performance Model for Multicore Architectures*, Communications of the ACM, 52(4), 2009, s. 65–76.
- [16] K. Datta i in., *Stencil Computation Optimization and Auto-tuning on State-of-the-Art Multicore Architectures*, Proceedings of the ACM/IEEE Conference on Supercomputing (SC'08), 2008.
- [17] G. M. Amdahl, *Validity of the Single Processor Approach to Achieving Large Scale Computing Capabilities*, AFIPS Conference Proceedings, vol. 30, 1967, s. 483–485.
- [18] Y. Chen, R. Griffith, J. Liu, R. H. Katz, A. D. Joseph, *Understanding TCP Incast Throughput Collapse in Datacenter Networks*, Proceedings of the 1st ACM Workshop on Research on Enterprise Networking (WREN), 2009.
- [19] P. Luszczek, J. J. Dongarra, i in., *Introduction to the HPC Challenge Benchmark Suite*, Technical Report ICL-UT-05-01, University of Tennessee, 2005.